31-5-2021

PRIMERA ENTREGA PROYECTO ANÁLISIS MULTIVARIADO

Miguel Barreto

Leonardo Perazza

Macarena Perdomo

1. Resumen Ejecutivo

El siguiente trabajo conforma la primera parte del proyecto final para la asignatura Análisis Multivariado. En esta primera instancia se aplicarán técnicas del análisis factorial sobre un set de datos compuesto por 48 países del continente americano y 22 variables del tipo sociodemográfico.

El set de datos presenta dificultad desde un primer momento con variables tales como *Coeficiente de Gini, Tabaco en adultos y Tabaco en Adolescentes* cuyos valores correspondientes a una gran cantidad de países del set, son faltantes. Las estrategias implementadas para superar esta dificultad son especificadas en la sección *Características de los datos.*

Para llevar acabo de estudio se seguirán los siguientes pasos:

- En primer lugar, se hace una restructuración del conjunto de datos, descartándose variables con muchos datos faltantes.
- Se aplica Análisis de Componentes principales al conjunto de datos y se hace una primera descripción.
- Se hacen modificaciones al conjunto de datos para mejorar la interpretación de los resultados.
- Se realizaron imputaciones por la media y por el vecino más cercano. Debido a que nos se encontraron diferencias en los resultados, se optó por la estrategia de imputar por la media. (Ver anexo)
- Se separan las variables originales en tres grupos y se aplica PCA a cada uno, haciéndose un análisis descriptivo.

2. Introducción

El objetivo de este trabajo es tratar de encontrar, a partir de la base de datos, cuales son los factores o variables en que los países de América más se diferencian entre sí. A partir de eso se evaluará la posibilidad de hacer agrupaciones de países relativamente parecidos, y si fuera posible, profundizar en un análisis considerando subgrupos disjuntos de variables, evaluando en dichos subgrupos la diferencia entre variables.

3. Marco Metodológico

Este proyecto se enmarca dentro de las unidades temáticas Análisis Factorial, Análisis de Componentes Principales y Análisis de Correspondencias Simples, del curso Análisis Multivariado.

Dado que la base de datos sobre la cual se trabajará no contiene variables del tipo cualitativas, la técnica a utilizar será Análisis de Componentes Principales.

La técnica PCA es debida a Hotelling (1933), aunque sus orígenes se encuentran en los ajustes ortogonales por mínimos cuadrados introducidos por K. Pearson (1901).

Daniel Peña (2002), afirma en el capítulo 5 de su libro *Análisis de Datos Multivariantes*:

Un problema central en el análisis de datos multivariantes es la reducción de dimensionalidad: si es posible describir con precisión los valores de p variables por un pequeño subconjunto r <p de ellas, se habrá reducido la dimensión del problema a costa de una pequeña pérdida de información.

Disponiéndose entonces de los valores de p-variables en n elementos de una población dispuestos en una matriz X de dimensiones $n \times p$ (en donde las columnas contienen las variables y las filas los elementos), PCA tiene el objetivo de representar adecuadamente esta información con un número reducido de nuevas variables (construidas como combinaciones lineales de las variables originales) a las que llamamos factores.

Asimismo, PCA se trata de un análisis fundamentalmente exploratorio, que intenta responder preguntas sobre la cercanía de los individuos y relación entre las variables trabajadas, buscando sintetizar la información que aportan las variables originales a las Componentes Principales.

Para la elección de las componentes principales a trabajar, se tomarán dos de los criterios descriptos en el libro de Jorge Blanco *Introducción al Análisis Multivariado,* esto son "La Regla de Kaiser" y el criterio "Scree Graph".

La **Regla de Kaiser** nos sugiere descartar aquellas componentes cuya inercia explicada (valor propio asociado) sea menor a 1 *"(…) dice Kaiser una componente que tenga varianza (inercia) menor que uno contiene menor información que la variable original y por lo tanto debe ser descartada."* Blanco, J. (2006) *Introducción al Análisis Multivariado.* Asimismo, según Blanco, la mayor limitación que tiene este criterio es su tendencia a elegir pocas componentes. **Scree Graph** nos propone un criterio gráfico para la elección de los componentes principales. En un diagrama

cartesiano, ubicamos en el eje de las abscisas el número de componentes ordenadas de forma decreciente, comenzando por aquella cuyo valor propio sea mayor, y sobre el eje de las ordenadas su correspondiente valor propio. *"(…) se trataba de buscar aquel punto más allá del cual el gráfico se vuelve aproximadamente una recta no necesariamente horizontal. (…)"* Blanco, J. (2006) *Introducción al Análisis Multivariado.*

4. Características de los datos

El trabajo se basa en un set de datos recogidos por la Organización Panamericana de la Salud (OPS), organismo afiliado a la Organización Mundial de la Salud (OMS) especializado en el sistema interamericano. El mismo cuenta con observaciones de 48 países del continente americano y 22 variables del tipo sociodemográfico.

El set de datos presenta dificultad desde un primer momento con los valores extraños registrados en la variable *Enfermeras cada 1000 habitantes,* así como también variables tales como *Coeficiente de Gini* y *Tabaco en adultos* cuyos valores correspondientes a una gran cantidad de países del set, son faltantes.

Con el fin de detectar la proporción de datos faltantes tanto por variable como por observación, y detectar si existe algún patrón en los mismos, se ha elaborado una tabla Excel con los datos a la que se le ha agregado dos últimas filas llamadas "Cantidad de blancos por variable" y "Proporción de Blancos por variable", así como también se agregaron al final las columnas "Cantidad de Blancos por Observación" y "Proporción de Blancos por Observación".

Este análisis arroja, por un lado, que las variables *Coeficiente de Gini, Tabaco en Adolescentes, Tabaco en Adultos, Gasto Público en Salud y Alcohol en Adultos* presentan un porcentaje de datos faltantes de 58%, 29%, 48%, 29% y 27% respectivamente. Por otro lado, encontramos variables tales como *Mortalidad Infantil, Mortalidad Neonatal,* Bajo Peso y *Cantidad de Médicos cada 1000 Habitantes* presentan un porcentaje de datos faltantes de 2%, destacándose *Cantidad de Enfermeras cada 1000 habitantes* con un porcentaje de 6%. Con respecto a las observaciones, se destaca *Islas Vírgenes (EUA)* con un porcentaje de datos faltantes de 41%.

Con el fin de centrar nuestro trabajo en la aplicación de las técnicas de Análisis Factorial y Análisis de Componentes principales, hemos decidido en primer lugar, descartar las variables con más de 10% de datos faltantes. Luego de esta primera modificación las variables que *Mortalidad Neonatal, Mortalidad Infantil* y *Bajo Peso* quedan con un solo dato faltante asociado a la misma observación: *Islas Vírgenes (EUA).*

La observación *Islas Vírgenes (EUA)* se mantendrá en el conjunto de datos para evaluar su influencia en el PCA como observación suplementaria.

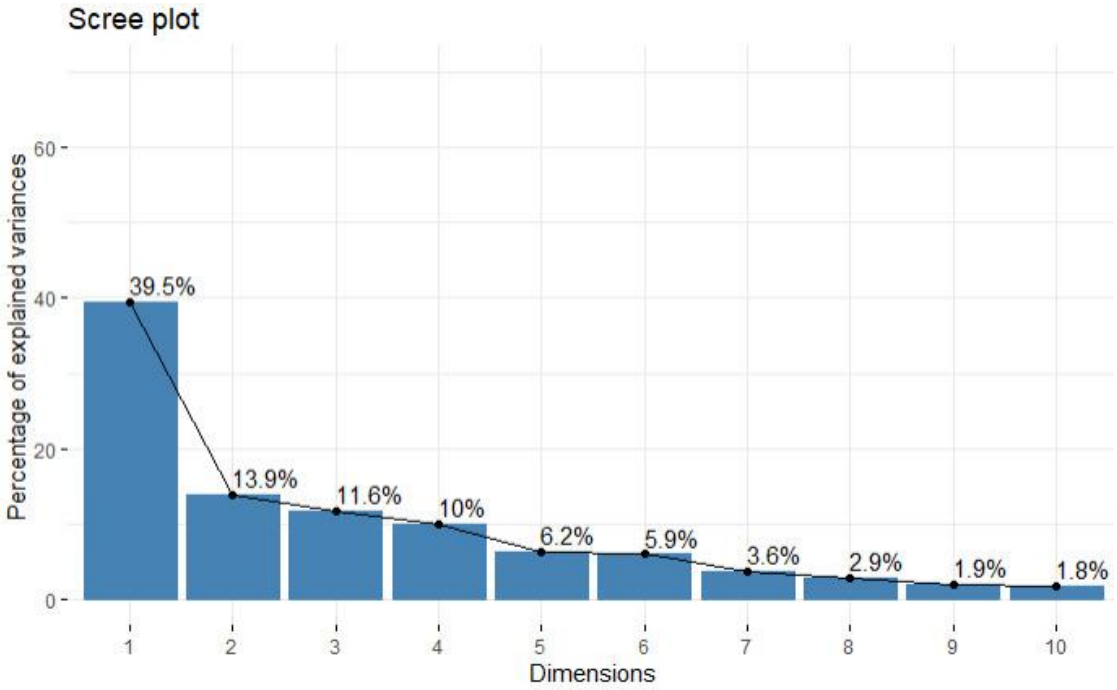
Tras las modificaciones realizadas se elabora un nuevo conjunto de datos al que hacemos referencia como "Data 2" con 16 variables y 48 observaciones.

5. Resultados del Análisis de Componentes Principales

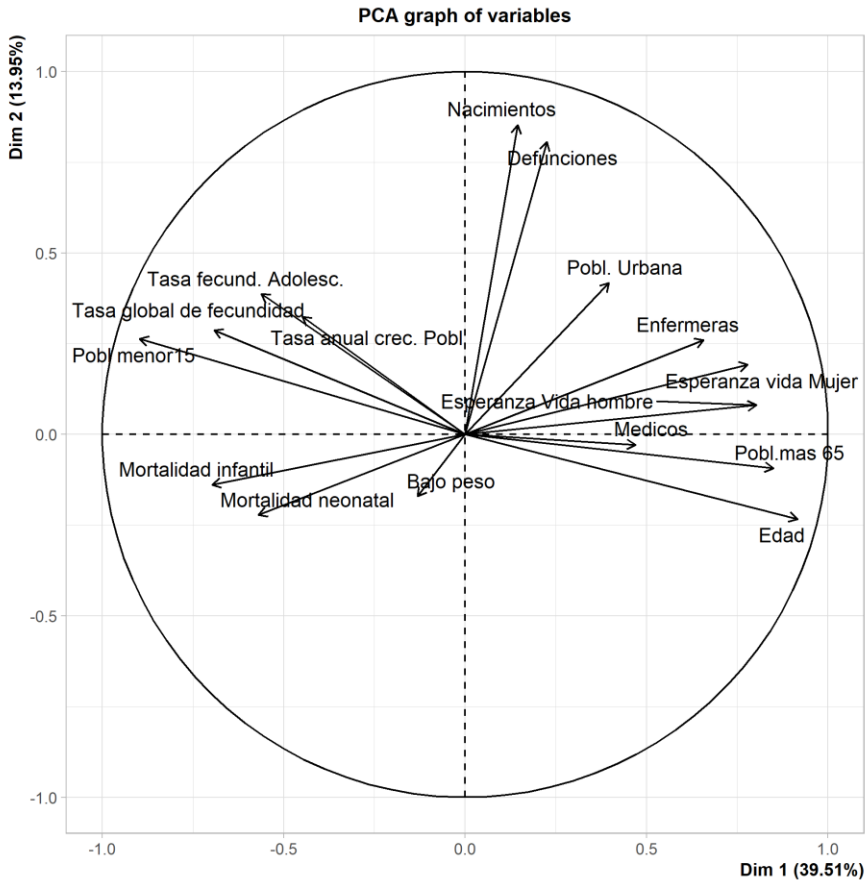
5.1 Primer acercamiento

Con respecto a los valores propios, observamos que aquellos asociados a los primeros siete ejes factoriales son mayores a uno, alcanzando con estos un porcentaje de varianza explicada del 78.5%.

	Dim.1	**Dim.2**	**Dim.3**	**Dim.4**	**Dim.5**	**Dim.6**	**Dim.7**
Var.	6.32	2.23	1.86	1.60	1.00	0.95	0.57
% de Var.	39.51	13.95	11.64	9.97	6.24	5.94	3.59
% de Var. Acumulada	39.51	53.46	65.10	75.07	81.30	87.24	90.83
	Dim.8	**Dim.9**	**Dim.10**	**Dim.11**	**Dim.12**	**Dim.13**	**Dim.14**
Var.	0.46	0.31	0.29	0.21	0.06	0.05	0.04
% de Var.	2.88	1.91	1.79	1.34	0.39	0.29	0.24
% de Var. Acumulada	93.71	95.61	97.41	98.74	99.14	99.43	99.67
	Dim.15	**Dim.16**					
Var.	0.03	0.03					
% de Var.	0.18	0.16					
% de Var. Acumulada	99.84	100.00					



Acorde a las sugerencias expuestas, se realiza un gráfico en el cual se colocan las dimensiones en el eje Ox de forma decreciente comenzando por aquella dimensión con mayor porcentaje de varianza explicada.



Al hacer un primer análisis del conjunto de variables y sus correlaciones con las dos primeras componentes, podemos observar que las variables más explicadas por la primera dimensión (Factor 1) son:

- **Edad** con una correlación de 0.916 con el primer eje factorial.
- **Población menor de 15** con una correlación de -0.897 con el primer eje factorial.
- **Población mayor de 65** con una correlación de 0.850 con el primer eje factorial.
- **Esperanza vida hombre** con una correlación de 0.803 con el primer eje factorial.
- **Esperanza de vida mujer** con una correlación de 0.779 con el primer eje factorial.

Por otra parte, las variables más explicadas por el segundo eje factorial son:

- **Nacimientos** con una correlación de 0.853 con el segundo eje factorial.
- **Defunciones** con una correlación de 0.806 con el segundo eje factorial.

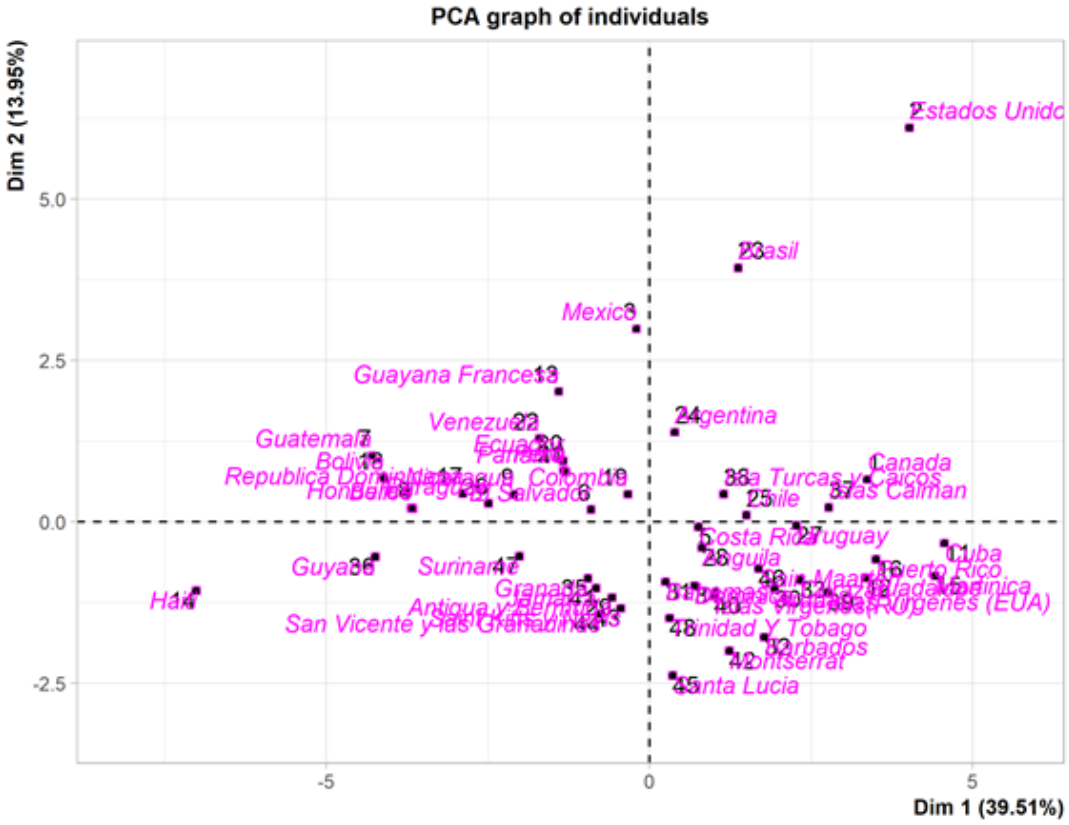
	Dim.1	Dim.2	Dim.3	Dim.4
Edad	13.28	2.44	0.02	1.42
Pobl menor 15	12.74	3.11	2.16	0.60
Pobl. Mas 65	11.43	0.39	0.19	0.06
Nacimientos	0.33	32.63	8.88	3.07
Defunciones	0.80	29.13	10.25	4.18
Tasa anual crec. Pobl	3.18	4.70	16.27	1.52
Tasa global de fecundidad	7.56	3.67	5.52	1.27
Tasa fecund Adolesc.	4.99	6.71	4.09	8.87
Pobl. Urbana	2.49	7.81	14.75	0.40
Esperanza Vida hombre	10.19	0.29	6.24	0.10
Esperanza vida Mujer	9.60	1.66	11.30	0.08
Mortalidad infantil	7.69	0.86	0.19	20.62
Mortalidad neonatal	5.13	2.22	0.03	30.28
Bajo peso	0.27	1.31	11.23	16.78
Medicos	3.49	0.04	8.78	0.63
Enfermeras	6.83	3.04	0.12	10.10

Mismas conclusiones pueden extraerse al analizar el indicador *contribución relativa.*

Alternativamente podemos medir la calidad de representación de las variables analizando el siguiente índice, el cual expresa la cercanía en términos de ángulos entre una variable y su proyección sobre un eje factorial. Sea el eje factorial F_s, sea la variable k y sea θ_s el ángulo que forma la variable con el eje F_s.

$$\cos \theta_s^2 = \frac{Inercia\ proyectada\ de\ la\ variable\ k\ en\ F_s}{Inercia\ total\ de\ la\ variable\ k} = Q_s$$

	Contribución				cos2			
	Dim.1	**Dim.2**	**Dim.3**	**Dim.4**	**Dim.1**	**Dim.2**	**Dim.3**	**Dim.4**
Edad	13.28	2.44	0.02	1.42	0.84	0.05	0.00	0.02
Pobl menor 15	12.74	3.11	2.16	0.60	0.81	0.07	0.04	0.01
Pobl mas 65	11.43	0.39	0.19	0.06	0.72	0.01	0.00	0.00
Nacimientos	0.33	32.63	8.88	3.07	0.02	0.73	0.17	0.05
Defunciones	0.80	29.13	10.25	4.18	0.05	0.65	0.19	0.07
Tasa annual crec. Pobl	3.18	4.70	16.27	1.52	0.20	0.10	0.30	0.02
Tasa global de fecundidad	7.56	3.67	5.52	1.27	0.48	0.08	0.10	0.02
Tasa fecund. Adolesc.	4.99	6.71	4.09	8.87	0.32	0.15	0.08	0.14
Pobl. Urbana	2.49	7.81	14.75	0.40	0.16	0.17	0.27	0.01
Esperanza Vida hombre	10.19	0.29	6.24	0.10	0.64	0.01	0.12	0.00
Esperanza vida Mujer	9.60	1.66	11.30	0.08	0.61	0.04	0.21	0.00
Mortalidad infantil	7.69	0.86	0.19	20.62	0.49	0.02	0.00	0.33
Mortalidad neonatal	5.13	2.22	0.03	30.28	0.32	0.05	0.00	0.48
Bajo peso	0.27	1.31	11.23	16.78	0.02	0.03	0.21	0.27
Medicos	3.49	0.04	8.78	0.63	0.22	0.00	0.16	0.01
Enfermeras	6.83	3.04	0.12	10.10	0.43	0.07	0.00	0.16



En el gráfico de los individuos se destaca, en primer lugar, que hay poca concentración de países con respecto al baricentro, quedando estos separados en los cuatro cuadrantes.

Países tales como *Costa Rica, Uruguay, Chile*, etc., cuyas ordenadas se encuentran cercanas a cero, es decir, cercanas al primer eje factorial, nos sugieren que tienen valores similares en las variables más explicadas por el primer eje factorial (mencionadas anteriormente) y además cercanos a la media de dichas variables.

De manera análoga ocurre con países tales como México o Argentina, los cuales se encuentran muy cercanos al segundo eje factorial (abscisa cercana a cero) nos indica que tienen valores similares en las variables más explicadas por el segundo eje factorial.

Como individuos **outliers,** aparecen Estados Unidos, Haití, Santa Lucía y Cuba. Los valores atípicos tienen importancia en el análisis, por lo que resulta importante saber cuánto su influencia afecta en la construcción de los componentes. Para ello analizamos la contribución relativa de estos individuos en los primeros cinco factores.

	Dimensión 1	*Dimensión 2*	*Dimensión 3*	*Dimensión 4*	*Dimensión 5*
Estados Unidos *Individuo 2*	7.463	28.009	18.009	9.039	2.832
Cuba *Individuo 11*	5.257	0.002	0.256	14.934	1.312
Haití *individuo 14*	15.959	2.828	7.799	1.868	17.635
Santa Lucía *Individuo 11*	0.567	2.322	3.906	0.221	14.578

Con respecto a Estados Unidos observamos que tiene valores altos en las variables *Defunciones* y *Nacimientos*, así como también en las variables asociadas al segundo factor relativas a la cantidad de población, lo cual parece razonable dado que es el país con mayor población de América.

En relación a Haití observamos que el hecho de que sea el país más alejado del segundo eje factorial, nos sugiere que su promedio de *Defunciones* y *Nacimientos* es bastante menor al resto de los países.

De forma similar ocurre con Cuba, quien figura como atípico en el cuarto cuadrante. Su posición nos sugiere que los valores en las variables más explicadas por la primera dimensión son cercanos a la media de todos los países, sin embargo, los valores en las variables más explicadas por la segunda dimensión son bastante superiores a ésta.

Como último punto destacado aparece *Santa Lucia,* poco explicado por el primer eje factorial, pero cercano al segundo, lo que nos indica que sus valores en las variables *Edad, Población menor de 15, Población mayor a 65, Esperanza de Vida Mujer, Esperanza de Vida Hombre* son bastante menores a la media del resto de los países estudiados.

Con respecto a la representación de los individuos en conjunto, observamos también, que los países con mayor superficie física tales como Estados Unidos, México, Canadá y Argentina tienen valores medios en las variables explicadas por el primer eje factorial muy por encima de la media, mientras que los países con menor superficie ocurren lo opuesto.

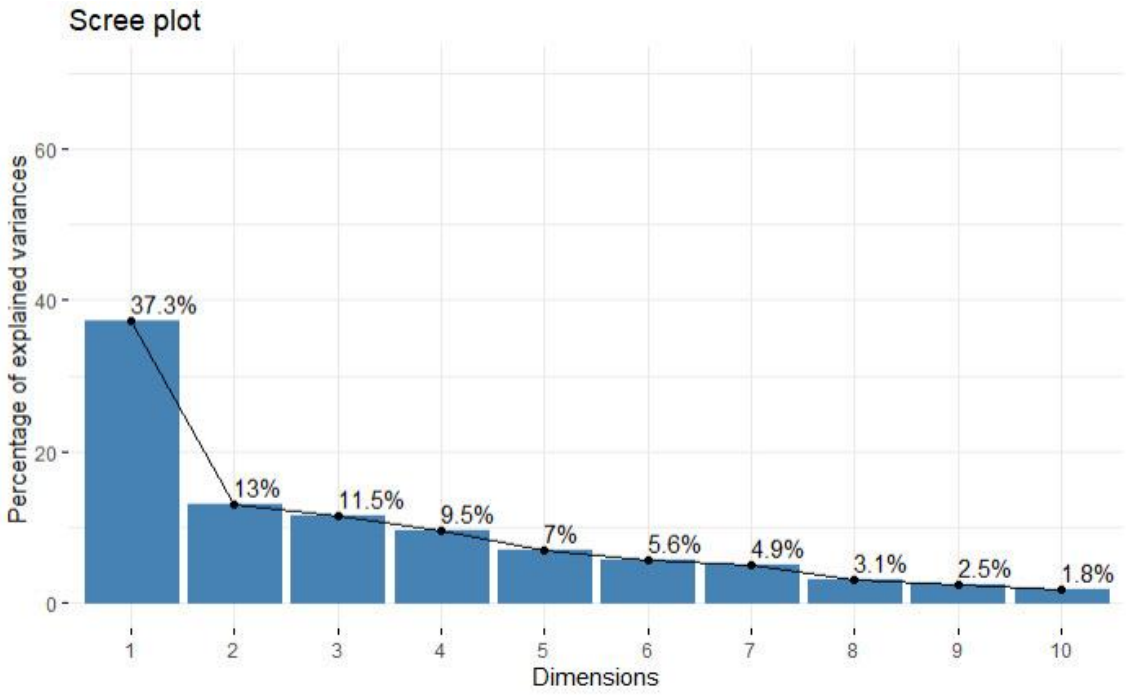
Atendiendo al hecho de que las variables *Defunciones* y *Nacimientos* medidas en cantidad cada 1000 habitantes, se ha decidido modificarlas para que los valores resultantes sean

proporcionales a su población. Para ello, multiplicamos cada valor por 1.000.000, lo dividimos entre su población y aplicamos PCA a el dataset modificado.

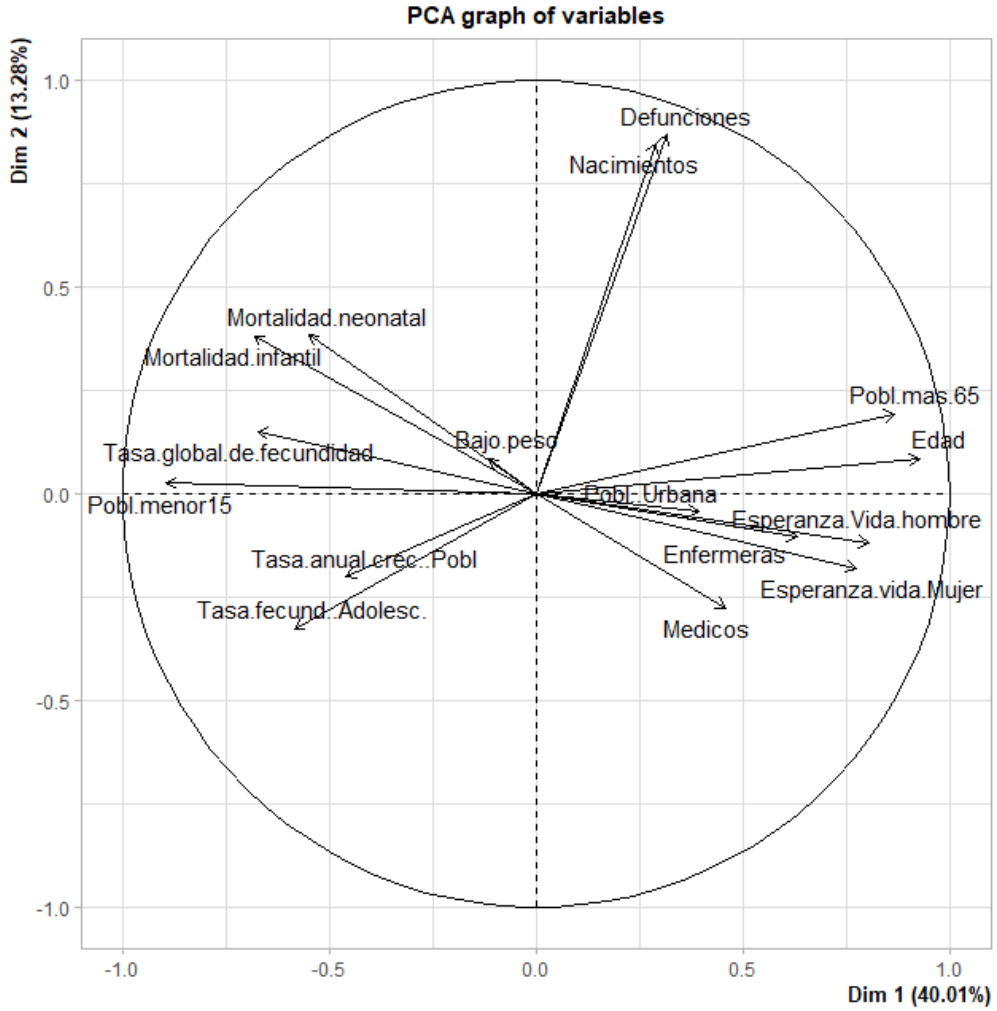
5.2 Segundo acercamiento: variables *Defunciones y Nacimientos* proporcionales a las poblaciones

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5	Dim.6	Dim.7
Var.	6.40	2.13	1.94	1.60	0.97	0.89	0.57
% de Var.	40.01	13.28	12.13	9.98	6.06	5.55	3.59
% de Var. Acumulada	40.01	53.29	65.42	75.40	81.45	87.00	90.58

Observamos que a partir del cuarto eje factorial inclusive, los valores propios asociados son mayores a 1, siendo estos suficientes para explicar el 75,4% de la variabilidad. Siguiendo el criterio de Kaiser, para el análisis de los datos modificados, parece razonable descartar los once restantes.



Al graficar las variables en la circunferencia de correlaciones se observa que no existen grandes diferencias en cuanto a las variables más explicadas por los ejes 1 y 2.



Variables más explicadas por el primer eje factorial:

- **Edad** con una correlación de 0.928 con el primer eje factorial.
- **Población menor de 15** con una correlación de -0.898 con el primer eje factorial.
- **Población mayor de 65** con una correlación de 0.861 con el primer eje factorial.
- **Esperanza vida hombre** con una correlación de 0.802 con el primer eje factorial.
- **Esperanza de vida mujer** con una correlación de 0.776 con el primer eje factorial.

Variables más explicadas por el segundo eje factorial:

- **Nacimientos** con una correlación de 0.848 con el segundo eje factorial.
- **Defunciones** con una correlación de 0.868 con el segundo eje factorial.

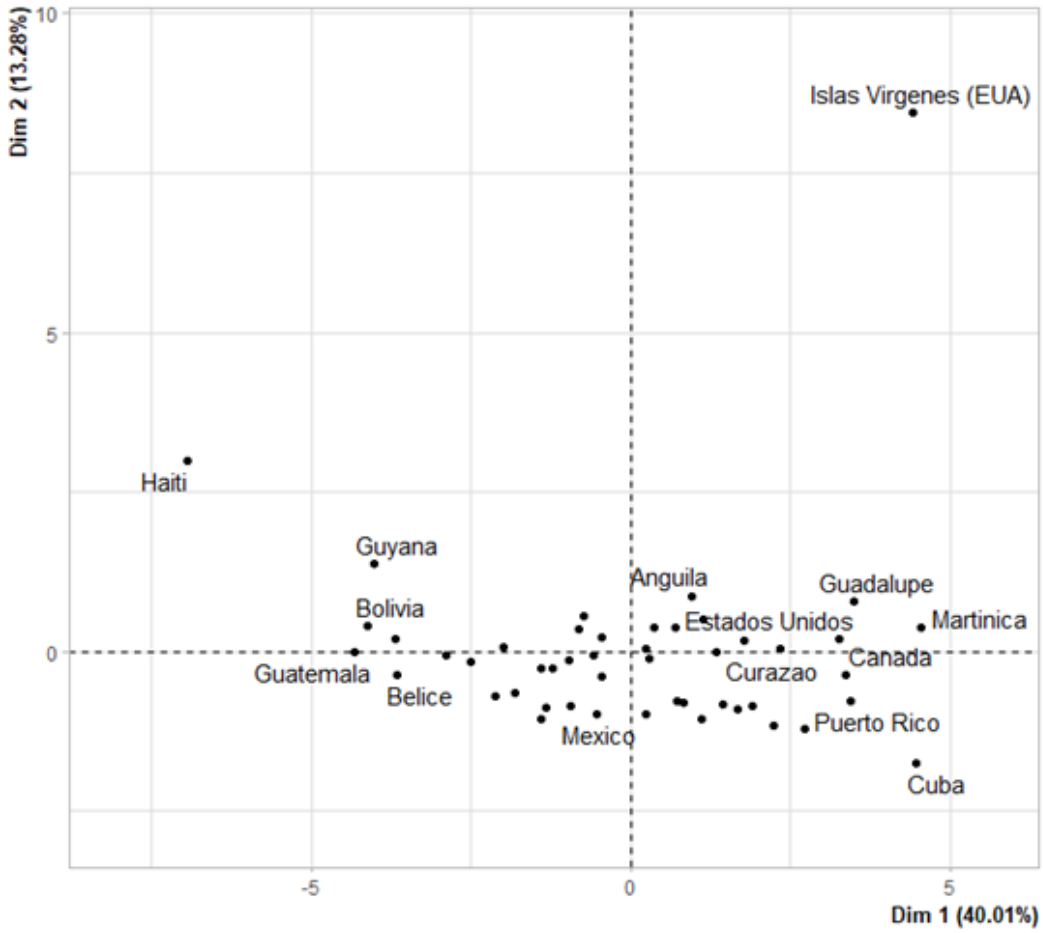
Contribución relativa de las variables a los primeros cuatro ejes factoriales

	Dim.1	Dim.2	Dim.3	Dim.4
Edad	13.31	1.23	0.07	2.13
Pobl menor 15	12.57	5.54	0.03	0.76
Pobl mas 65	11.55	0.49	0.00	0.01
Nacimientos	0.60	5.03	33.14	4.58
Defunciones	2.10	3.64	31.15	1.15
Tasa annual crec. Pobl	2.75	23.06	0.55	2.06
Tasa global de fecundidad	7.66	10.82	0.02	1.38
Tasa fecund. Adolesc.	4.94	7.50	8.56	4.34
Pobl. Urbana	2.09	18.81	4.27	1.57
Esperanza Vida hombre	10.03	5.83	0.12	0.01
Esperanza vida Mujer	9.39	11.11	1.23	0.17
Mortalidad infantil	7.66	0.95	2.79	16.39
Mortalidad neonatal	4.94	0.53	5.47	25.91
Bajo peso	0.27	2.21	0.05	27.00
Medicos	3.27	1.17	10.56	8.08
Enfermeras	6.86	2.08	1.99	4.45

Coseno cuadrado de las variables con los primeros cuatro ejes factoriales

	Dim.1	Dim.2	Dim.3	Dim.4
Edad	0.86	0.01	0.02	0.03
Pobl menor 15	0.80	0.00	0.11	0.02
Pobl. Mas 65	0.75	0.04	0.00	0.00
Nacimientos	0.08	0.72	0.06	0.05
Defunciones	0.10	0.75	0.06	0.04
Tasa anual crec. Pobl	0.21	0.04	0.34	0.06
Tasa global de fecundidad	0.45	0.02	0.25	0.05
Tasa fecund. Adolesc.	0.34	0.11	0.15	0.10
Pobl. Urbana	0.16	0.00	0.48	0.00
Esperanza Vida hombre	0.65	0.01	0.10	0.00
Esperanza vida Mujer	0.60	0.03	0.22	0.00
Mortalidad infantil	0.46	0.15	0.00	0.22
Mortalidad neonatal	0.30	0.15	0.00	0.39
Bajo peso	0.01	0.01	0.07	0.43
Medicos	0.21	0.08	0.05	0.09
Enfermeras	0.40	0.01	0.02	0.12

Sin embargo, se observan cambios en el gráfico de los individuos.



Haití y Cuba vuelven a aparecer como individuos atípicos, con altas contribuciones relativas a las dos primeras componentes principales, mientras que Estados Unidos y Santa Lucía se concentran cerca del baricentro con coordenadas (3.268, 0.1961) y (0.365, 0.367) respectivamente.

Esto último nos indica que, para Estados Unidos, sus valores en *Nacimientos* y *Defunciones* proporcionales a la población, están muy cercanos a la media del resto de los países. Mientras que los valores en las variables mejor explicadas por la primera dimensión siguen siendo mayor que la media del resto de los países.

De forma análoga ocurre con Santa Lucía.

También es posible observar, a través de las contribuciones relativas, cómo estos puntos dejan de ser influyentes en la construcción del primer y segundo eje.

	CTR dimensión 1	*CTR dimensión 2*
Estados Unidos	3.477	0.037
Santa Lucía	0.043	0.132

Se destaca Islas Vírgenes (EUA) con una contribución relativa de 6.324 y 69.890 con el primer y segundo eje factorial respectivamente. Esto nos sugiere que sus valores en las variables explicadas por primera y segunda dimensión son muy superiores a la media del resto de los países.

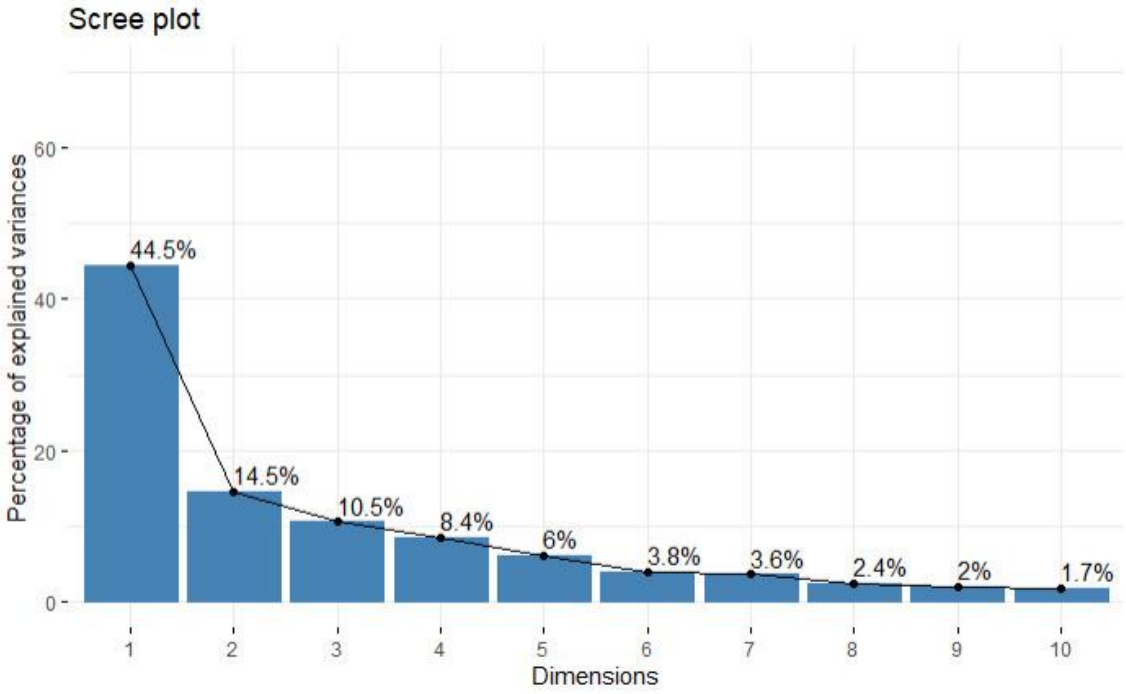
Islas Vírgenes (EUA) resulta una observación problemática presentando mayor cantidad de datos faltantes, encontrándose los mismos en las variables *Mortalidad Infantil, Mortalidad Neonatal, Médicos cada 1000 habitantes* y *Enfermeras cada 1000 habitantes,* seleccionamos a esta variable como suplementaria. Curazao y Saint Maarten presentan datos faltantes en

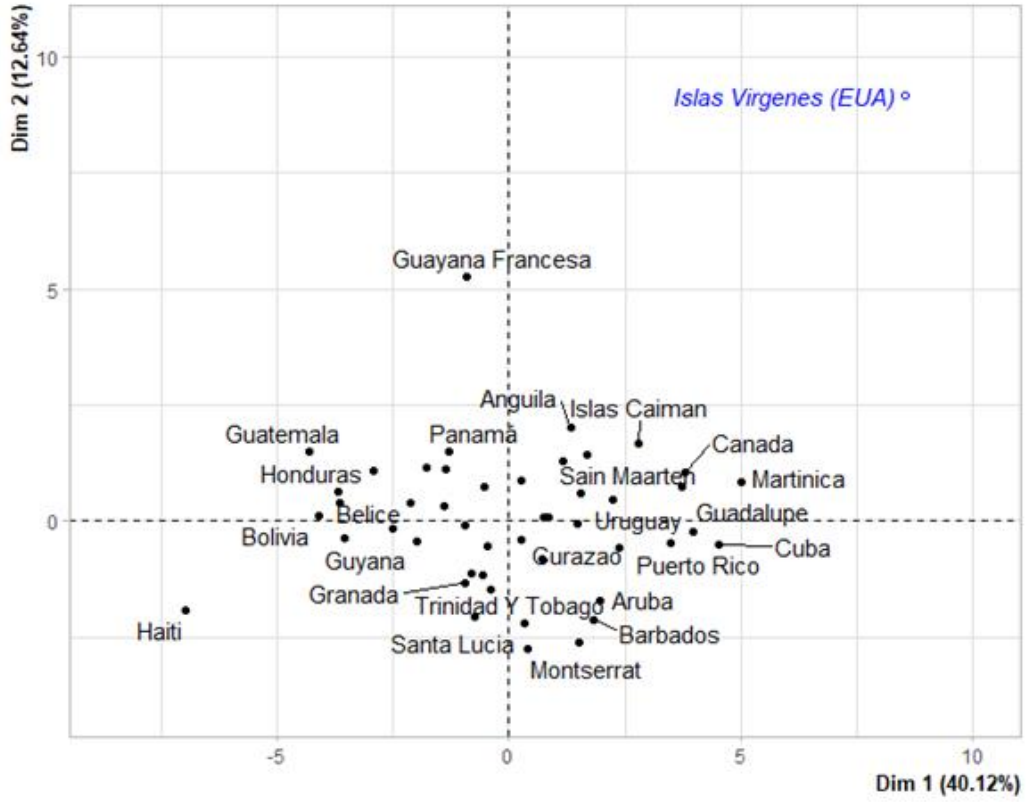
5.3 Tercer acercamiento: observación con datos faltantes como suplementaria

Esta modificación en la consideración de las variables para PCA provoca cambios en varios aspectos de análisis.

En primer lugar, observamos que al incluir Islas Vírgenes (EUA) como variable suplementaria, tenemos que las primeras cinco dimensiones serían las más relevantes (criterio Kaiser), explicando un 81% de la variabilidad.

	Dim.1	**Dim.2**	**Dim.3**	**Dim.4**	**Dim.5**	**Dim.6**	**Dim.7**
Var.	6.42	2.02	1.87	1.63	1.04	0.86	0.57
% de Var.	40.12	12.64	11.67	10.16	6.52	5.36	3.55
% de Var. Acumulada	40.12	52.76	64.44	74.59	81.11	86.47	90.02

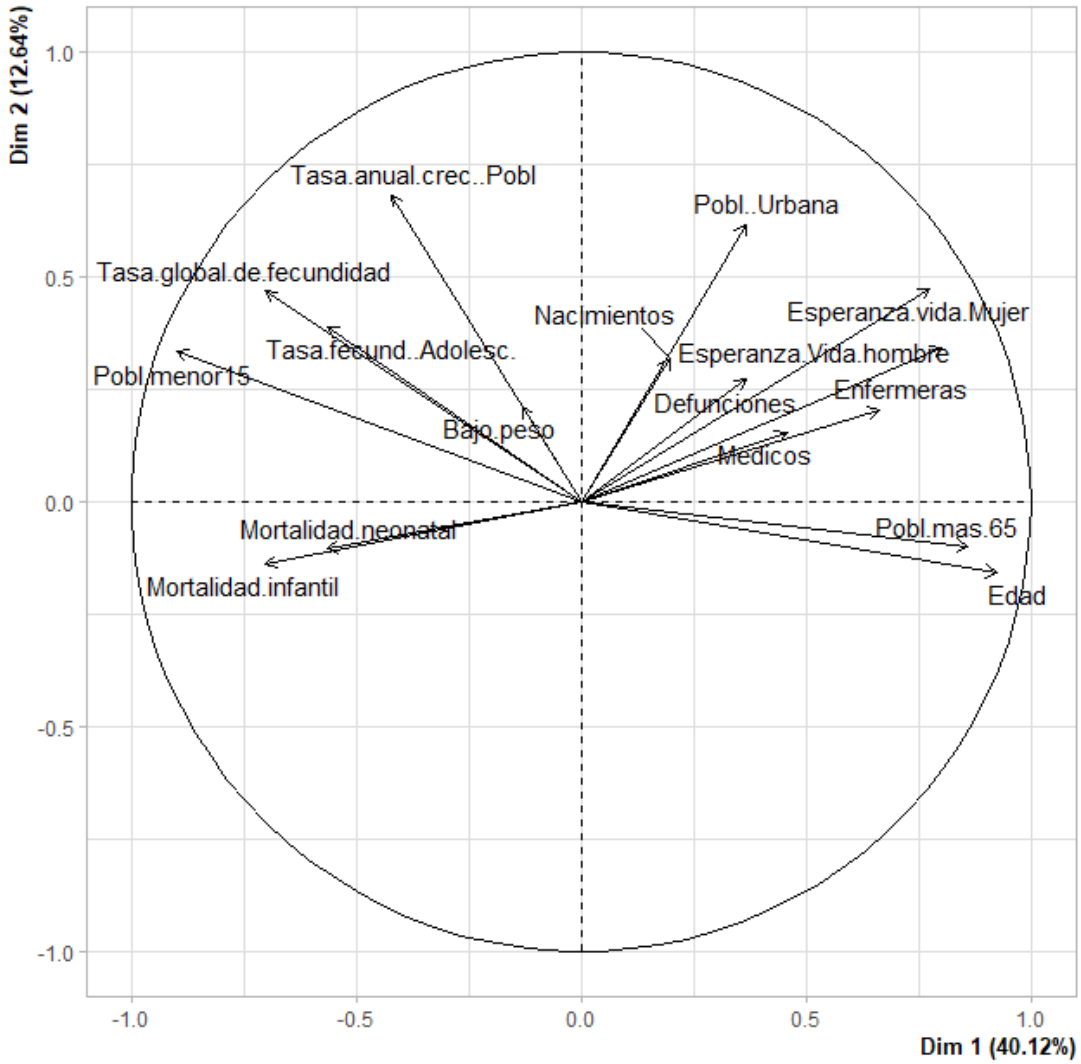




En segundo lugar, se observan cambios en el gráfico de los individuos, destacándose Haití, Santa Lucía, Martinica y Guyana Francesa como puntos extremos, con contribuciones relativas:

	CTR dimensión 1	*CTR dimensión 2*
Haití	16.107	3.864
Guyana Francesa	0.273	29.134
Martinica	8.288	0.752
Santa Lucía	0.052	7.902

En tercer lugar, se observan cambios en el gráfico de correlaciones entre variables y ejes factoriales.



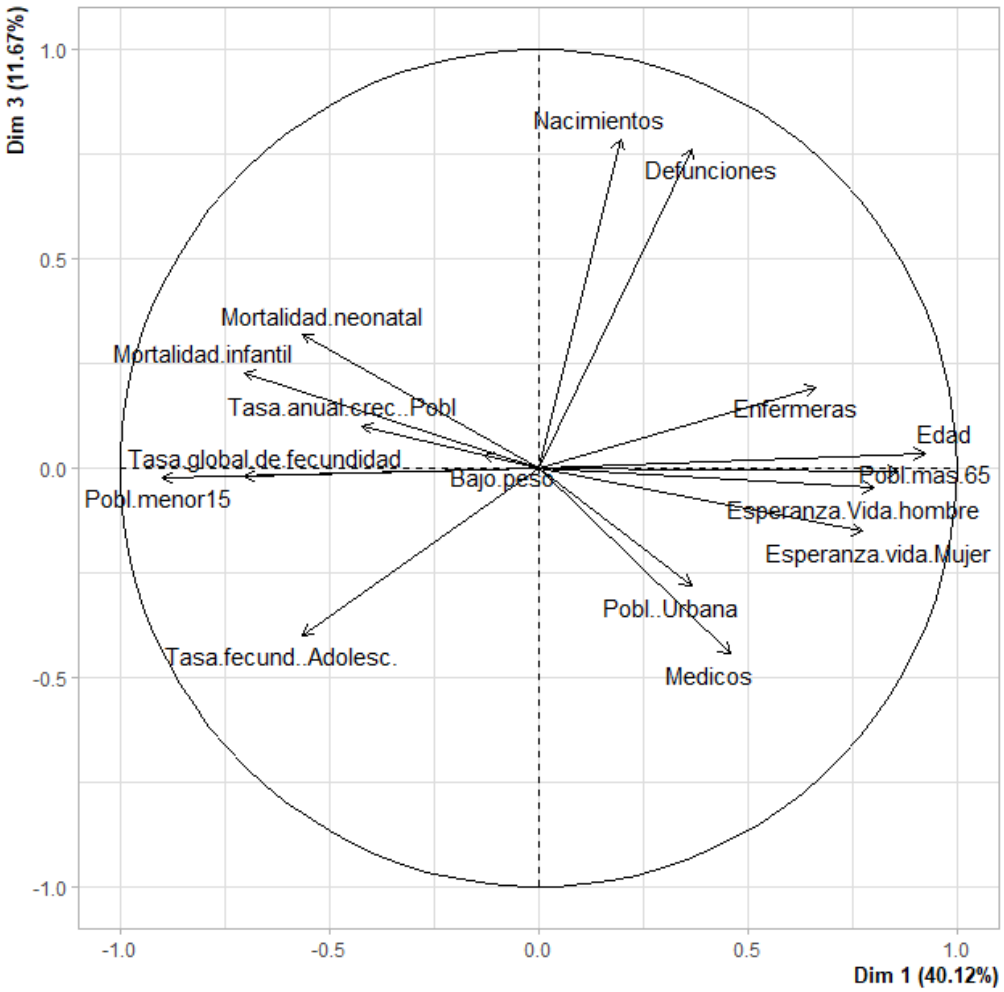
Correlaciones con los primeros ejes factoriales

	Dim.1	Dim.2	Dim.3	Dim.4
Edad	0.92	-0.16	0.04	0.19
Pobl menor 15	-0.90	0.33	-0.02	-0.11
Pobl mas 65	0.86	-0.10	-0.01	0.02
Nacimientos	0.20	0.32	0.79	-0.27
Defunciones	0.37	0.27	0.76	-0.14
Tasa annual crec. Pobl	-0.42	0.68	0.10	0.18
Tasa global de fecundidad	-0.70	0.47	-0.02	-0.15
Tasa fecund. Adolesc.	-0.56	0.39	-0.40	-0.27
Pobl. Urbana	0.37	0.62	-0.28	0.16
Esperanza Vida hombre	0.80	0.34	-0.05	0.01
Esperanza vida Mujer	0.78	0.47	-0.15	0.05
Mortalidad infantil	-0.70	-0.14	0.23	0.52
Mortalidad neonatal	-0.56	-0.10	0.32	0.65
Bajo peso	-0.13	0.21	0.03	0.66
Medicos	0.46	0.15	-0.44	0.36
Enfermeras	0.66	0.21	0.19	0.27

Variables más explicadas por la primera dimensión y sus correlaciones con la misma.

- **Edad** 0.924.
- **Población menor de 15** -0.898
- **Población mayor** 65 0.861
- **Taza global de fecundidad** -0.701
- **Esperanza de vida hombre** 0.803
- **Esperanza de vida mujer** 0.776
- **Mortalidad Infantil** -0.701

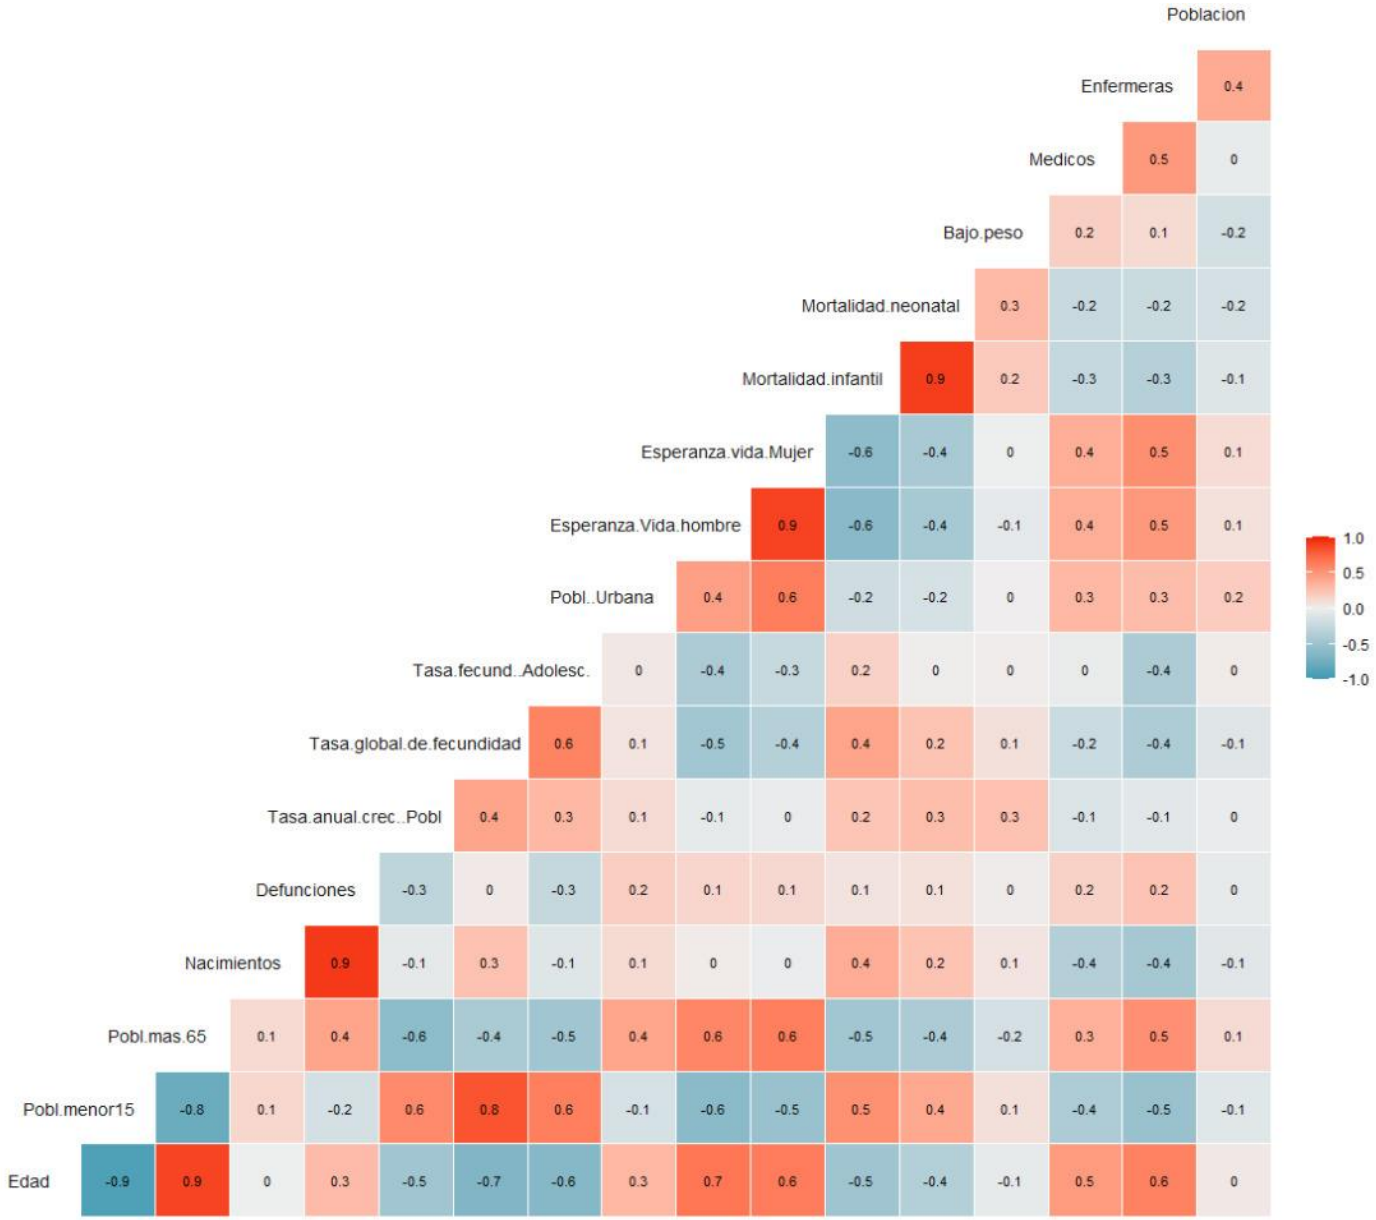
Observamos que no existen fuertes correlaciones (mayores a 0.7) con la segunda dimensión, y que las variables Nacimientos y Defunciones, mejor explicadas por el 2do eje en el análisis sin seleccionar a Islas Vírgenes (EUA) como observación suplementaria, son mejor explicadas por el tercer eje factorial con correlaciones de 0.787 y 0.762 respectivamente.



5.4 Cuarto acercamiento: agrupación de variables

En los acercamientos anteriores pudimos detectar que existen ciertas correlaciones destacables entre las variables del set de datos, las cuales resulta interesante estudiar. Para ello, se incluyó en el data set la variable *Población* cuyos valor son los últimos datos actualizados de la página del Banco Mundial, y se realizó un gráfico de correlaciones dos a dos entre variables.

Asimismo, se ha decidido remover de la base de datos la variable problemática Islas Vírgenes (EUA).



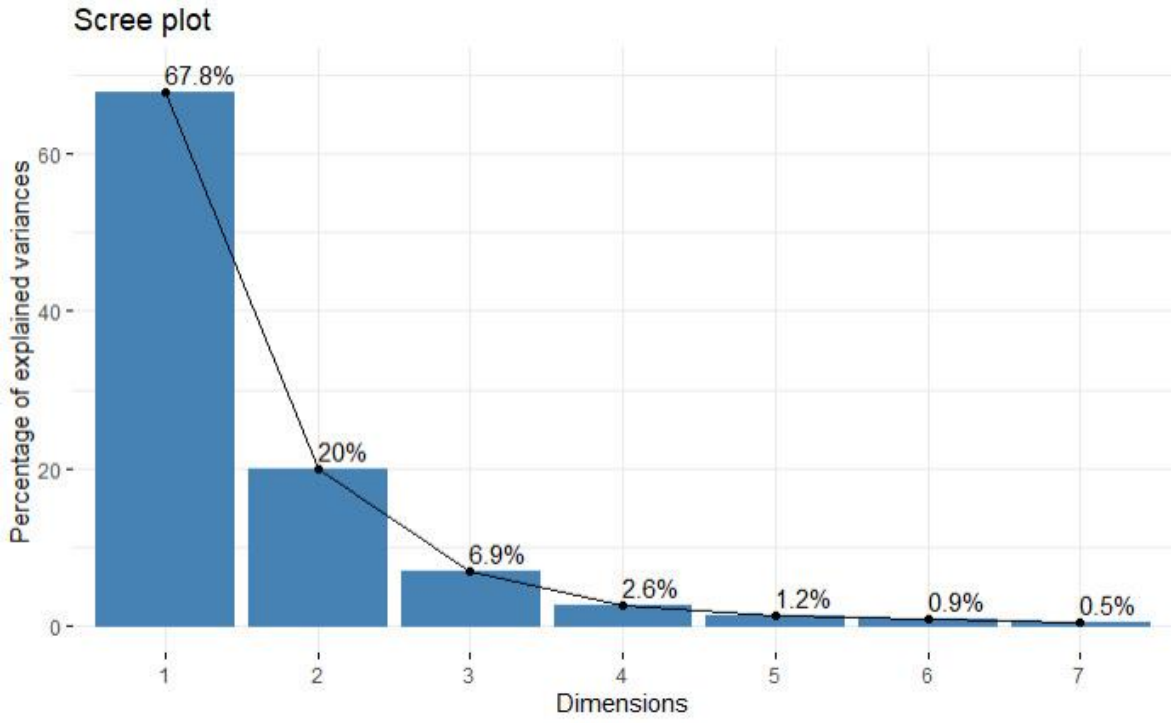
Este gráfico nos sugiere la siguiente agrupación de variables, para el cual haremos nuevamente un análisis exploratorio y descriptivo:

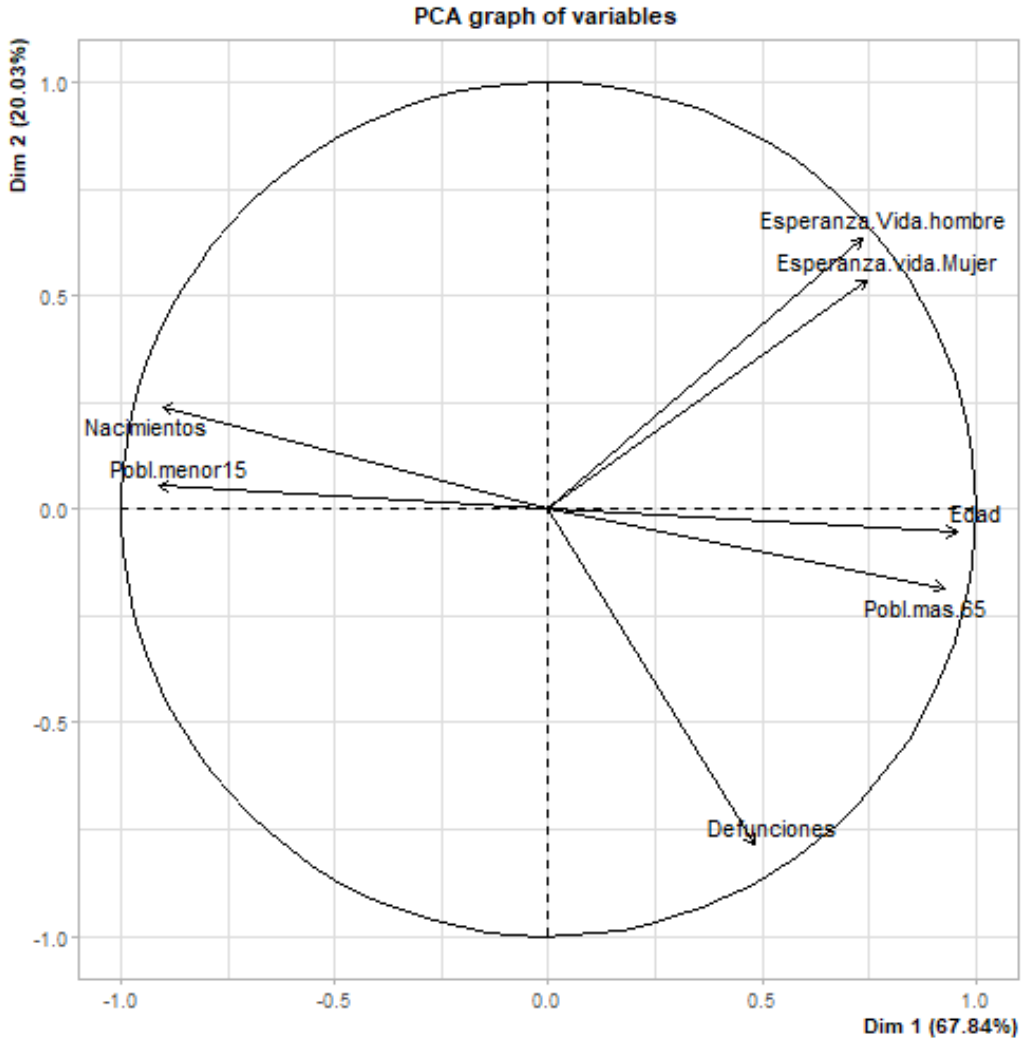
	Variables	Descripción de los grupos
Grupo 1	• Edad. • Población menor de 15. • Población mayor a 65. • Nacimientos. • Defunciones. • Esperanza de vida mujer. • Esperanza de vida hombre.	Relativas a la edad de la población.
Grupo 2	• Tasa anual de crecimiento población. • Tasa global de fecundidad. • Tasa fecundidad adolescente. • Población urbana. • Población.	Relativas al crecimiento poblacional.
Grupo 3	• Bajo Peso. • Médicos por cada 100.000 habitantes. • Enfermeras por cada 100.000 habitantes. • Mortalidad neonatal. • Mortalidad infantil.	Relativas a la mortalidad infantil.

Grupo 1

Aplicamos PCA al primer grupo y observamos que acorde a la regla de Kaiser, los dos primeros ejes factoriales sería suficiente para describir el análisis de este grupo, explicándose con éstos un 80% de la variabilidad.

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5	Dim.6	Dim.7
Var.	4.75	1.40	0.49	0.18	0.09	0.06	0.03
% de Var.	67.84	20.03	6.93	2.58	1.24	0.91	0.48
% de Var. Acumulada	67.84	87.86	94.79	97.37	98.61	99.52	100.00


Scree plot
Percentage of explained variances
Dimensions
67.8%
20%
6.9%
2.6%
1.2%
0.9%
0.5%
0
20
40
60
1
2
3
4
5
6
7

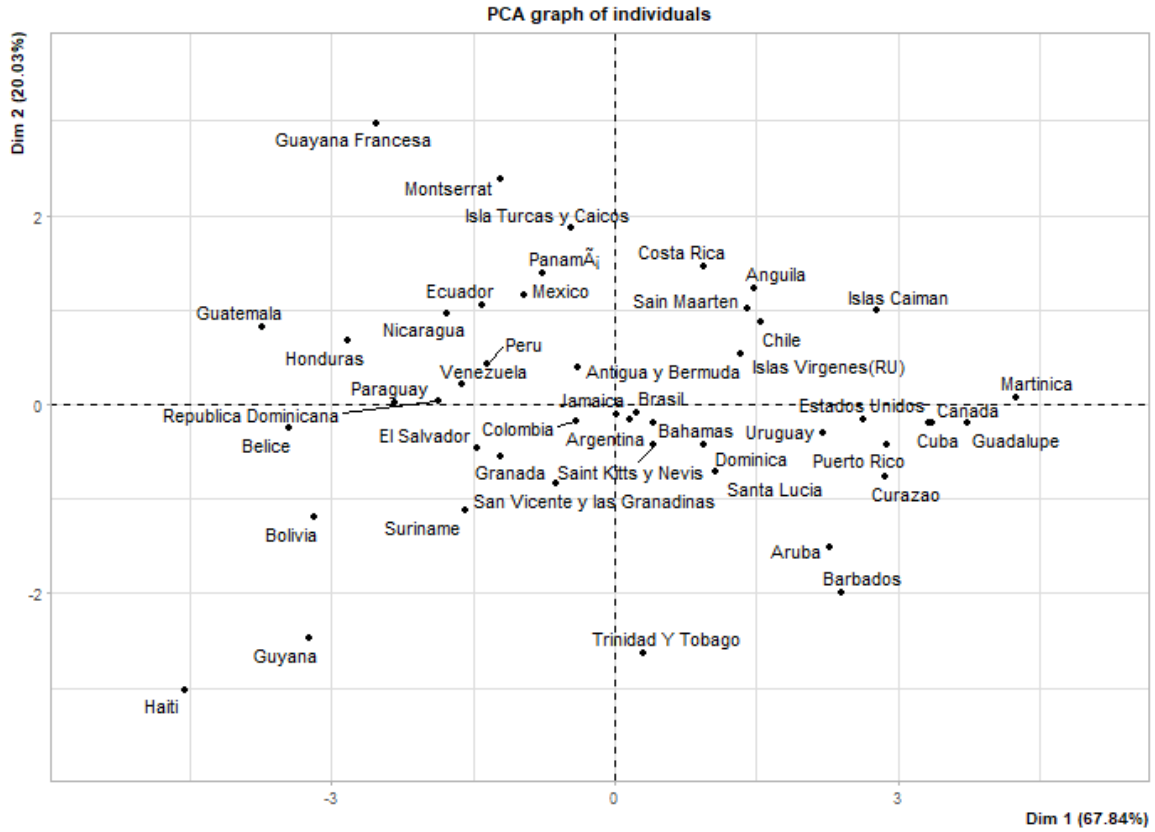

PCA graph of variables
Dim 2 (20.03%)
Dim 1 (67.84%)
Esperanza.Vida.hombre
Esperanza.vida.Mujer
Nacimientos
Pobl.menor15
Edad
Pobl.mas.65
Defunciones
1.0
0.5
0.0
-0.5
-1.0

Analizando tanto el gráfico de correlaciones con las primeras dimensiones y los indicadores $coseno^2$ y contribución relativa, podemos concluir que todas las variables están bien explicadas por estos primeros ejes factoriales.

	Correlación		cos2		Contribución	
	Dim.1	Dim.2	Dim.1	Dim.2	Dim.1	Dim.2
Edad	0.96	-0.05	0.92	0.00	19.31	0.21
Pobl menor 15	-0.91	0.05	0.83	0.00	17.40	0.20
Pobl mas 65	0.93	-0.18	0.86	0.03	18.12	2.42
Nacimientos	-0.90	0.24	0.81	0.06	17.11	4.11
Defunciones	0.48	-0.79	0.23	0.62	4.90	44.05
Esperanza Vida hombre	0.74	0.63	0.54	0.40	11.42	28.55
Esperanza vida Mujer	0.75	0.54	0.56	0.29	11.75	20.47

En relación a los individuos se observan varios puntos extremos tales como Guayana Francesa, Haití y Martinica, con las siguientes contribuciones relativas:

	Dim.1	Dim.2
Guayana Francesa	2.86	13.45
Haiti	9.33	13.86
Martinica	8.1	0.01



Martinica, Canadá, Estados Unidos, Cuba y Guadalupe presentan valores por encima de la media en Población mayor a 65 , y por debajo de la media para población menor a 15

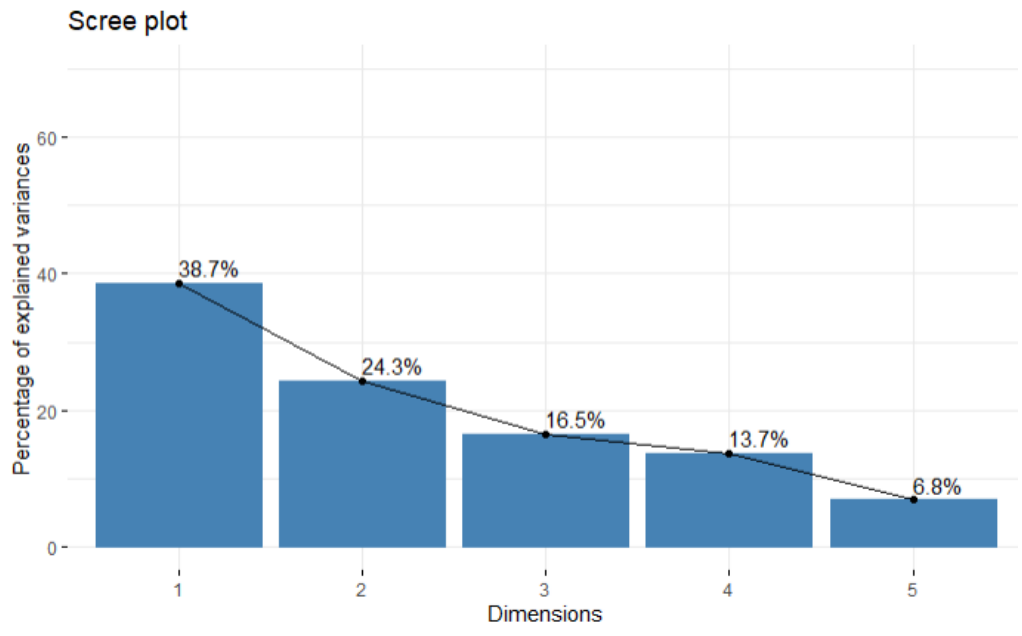
Países tales como Estados Unidos, Guadalupe, Canadá y Martinica presentan valores muy superiores a la media en las variables *Población menor de 15 años, Población mayor de 65, Edad, Esperanza de Vida Hombre, Esperanza de Vida Mujer, Nacimientos y Defunciones.* Mientras que Guyana, Guayana Francesa y Haití, si bien también tienen valores en las variables antes mencionadas muy superiores a la media del resto de los países, sus valores para *Nacimientos* y *Defunciones* resultan por debajo de la media.

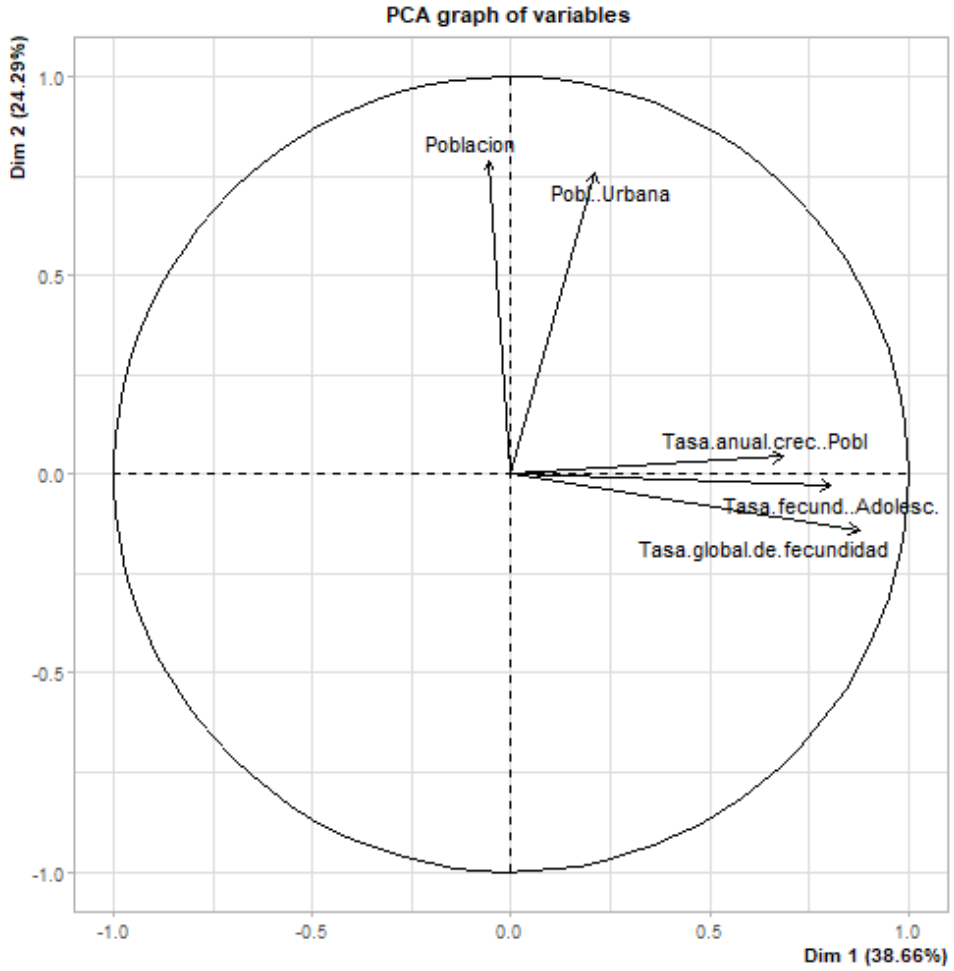
Por último, tenemos a Cuba, como punto más extremo en el cuarto cuadrante, indicándonos que sus valores en las variables asociadas tanto a primera como a segunda dimensión son muy inferiores a la media del resto de las observaciones.

Grupo 2

Aplicamos PCA al primer grupo y observamos que acorde a la regla de Kaiser, los dos primeros ejes factoriales sería suficiente para describir el análisis de este grupo, explicándose con éstos un 63% de la variabilidad.

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Var.	1.93	1.21	0.83	0.68	0.34
% de Var.	38.66	24.29	16.55	13.68	6.82
% de Var. Acumulada	38.66	62.95	79.49	93.18	100.00

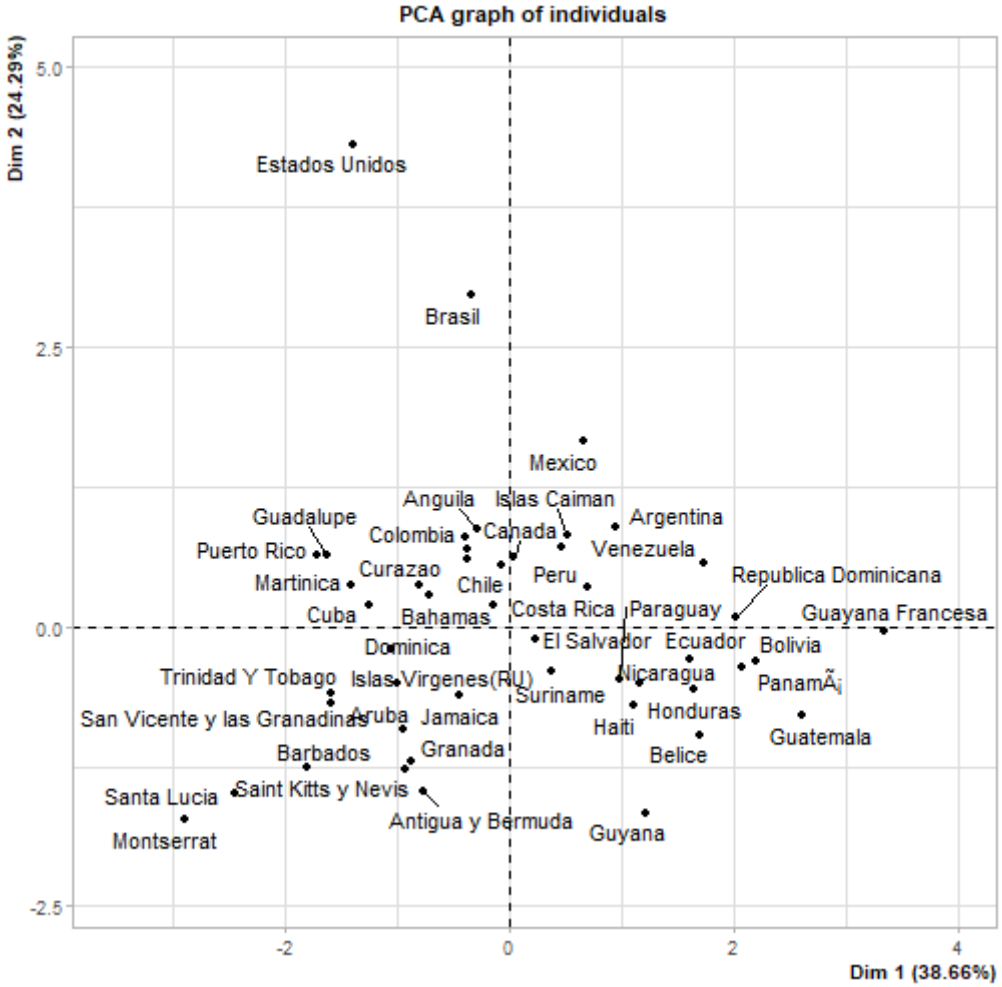




	Correlación		cos2		Contribución	
	Dim.1	**Dim.2**	**Dim.1**	**Dim.2**	**Dim.1**	**Dim.2**
Tasa annual crec. Pobl	0.68	0.04	0.47	0.00	24.26	0.16
Tasa.global de fecundidad	0.88	-0.14	0.77	0.02	39.68	1.61
Tasa fecund. Adolesc.	0.81	-0.03	0.65	0.00	33.57	0.07
Pobl. Urbana	0.21	0.76	0.04	0.57	2.33	47.11
Poblacion	-0.06	0.79	0.00	0.62	0.16	51.05

En relación a las variables del grupo 2, observamos que aquellas mejor explicadas por la primera dimensión son *Tasa de Fecundidad Adolescente, Tasa Global de Fecundidad y Tasa de Crecimiento Poblacional;* mientras que las variables mejor explicadas por la segunda dimensión son *Población* y *Población Urbana.*

Destacamos la correlación existente entre la Tasa *de Fecundidad Adolescente* y *Tasa de Crecimiento Poblacional.*



En el gráfico de los individuos se observan como atípicos a Brasil, Estados Unidos, Monserrat y Guyana Francesa.

Analizamos las contribuciones relativas de los individuos en la construcción de las dimensiones, destacándose:

	Dim.1	Dim.2
Estados Unidos	2.15	32.53
Mexico	0.48	4.78
Guayana Francesa	3.34	-0.05
Montserrat	9.27	5.19

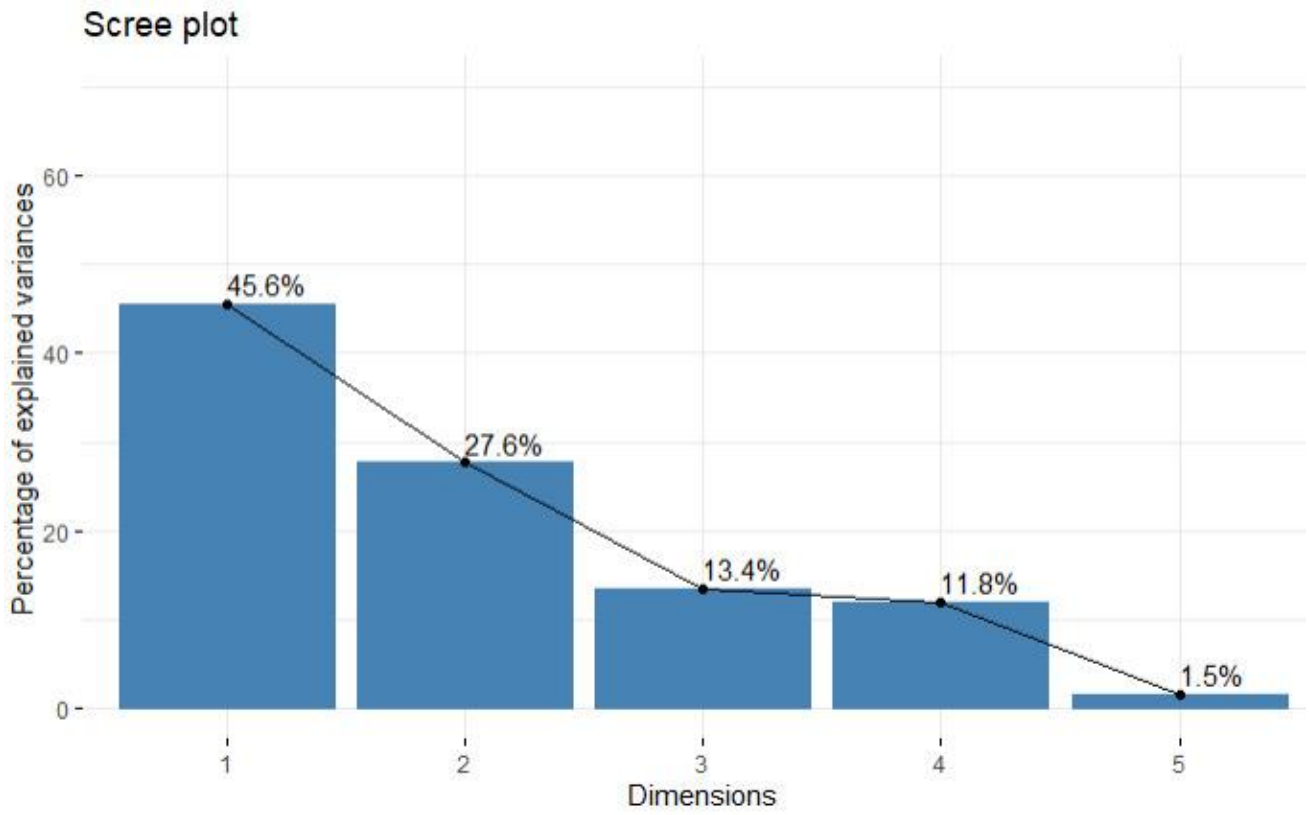
De esta descripción podemos concluir que Brasil y México tienen valores de Tasa de Fecundidad Adolescente, Tasa Global de Fecundidad y Tasa de Crecimiento Poblacional muy superiores a la media del resto de los países.

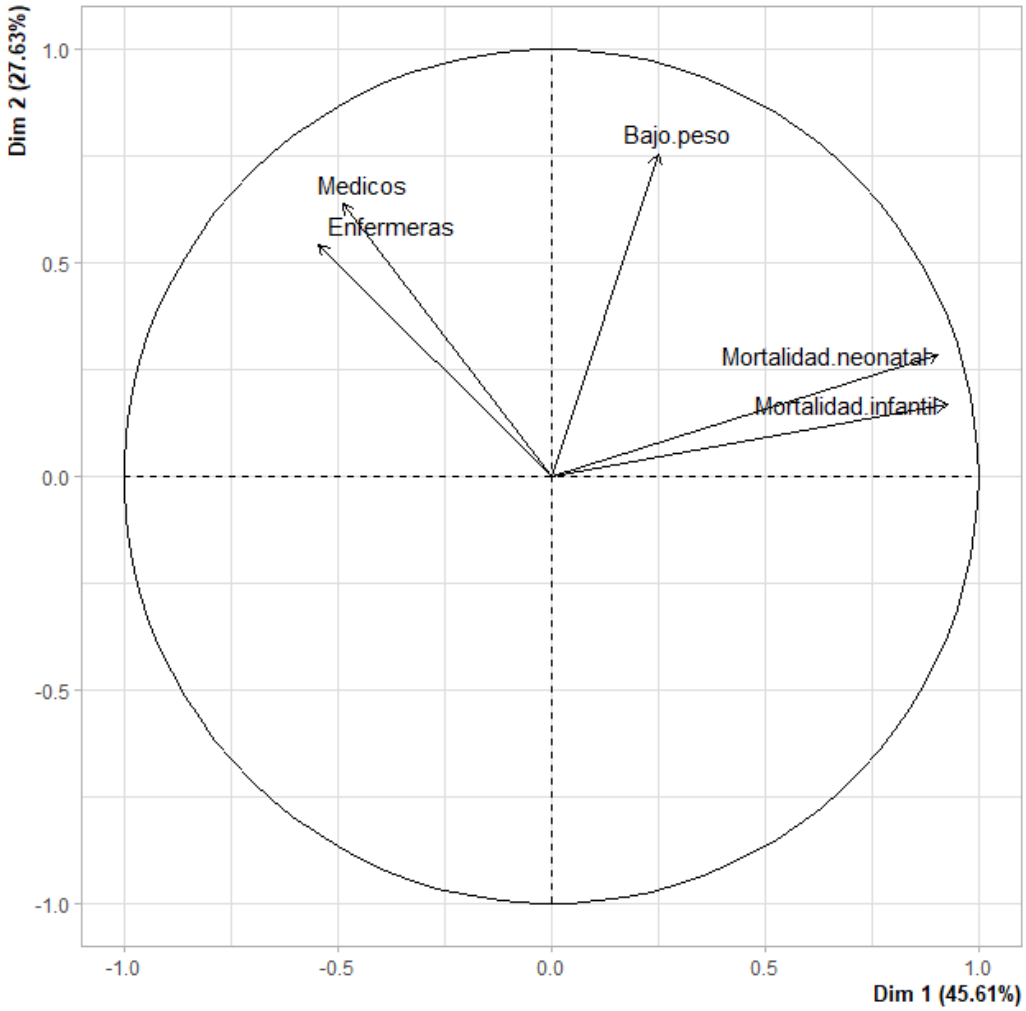
Países como Guyana Francesa, Monserrat y Santa Lucía presentan valores de población y población urbana muy inferiores a la media del resto de los países, así como también valores inferiores de fecundidad en adolescentes, fecundidad global y crecimiento poblacional.

Grupo 3

Aplicamos PCA al primer grupo y observamos que acorde a la regla de Kaiser, los dos primeros ejes factoriales sería suficiente para describir el análisis de este grupo, explicándose con éstos un 73% de la variabilidad.

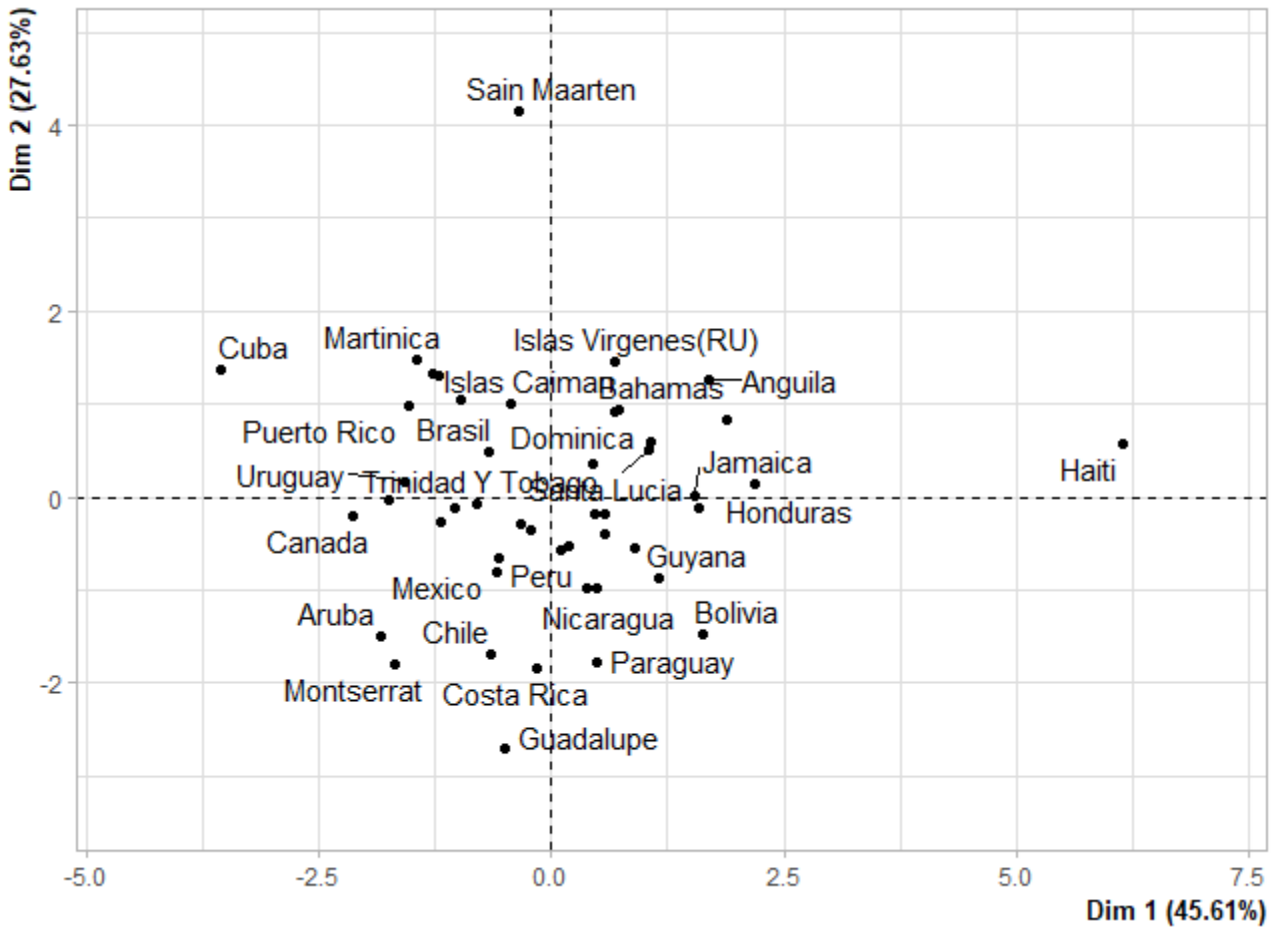
	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
Var.	2.28	1.38	0.67	0.59	0.08
% de Var.	45.61	27.63	13.41	11.85	1.50
% de Var. Acumulada	45.61	73.25	86.66	98.51	100.00





	Correlación		cos2		Contribución	
	Dim.1	**Dim.2**	**Dim.1**	**Dim.2**	**Dim.1**	**Dim.2**
Bajo peso	0.25	0.75	0.06	0.57	2.78	41.25
Medicos	-0.49	0.64	0.24	0.41	10.40	29.39
Enfermeras	-0.54	0.54	0.29	0.30	12.93	21.43
Mortalidad neonatal	0.91	0.28	0.82	0.08	36.03	5.84
Mortalidad infantil	0.93	0.17	0.86	0.03	37.86	2.10

En relación a las variables del tercer grupo, vemos que *Mortalidad Infantil* y *Mortalidad Neonatal* se encuentran mayormente explicadas por la primera dimensión, mientras que *Bajo Peso* tiene una fuerte correlación con dimensión dos, siendo la variable mejor explicada por esta. Con respecto a las variables *Médicos* y *Enfermeras*, observamos que son necesarias ambas dimensiones para ser estar bien explicadas.



En el gráfico de los individuos se destacan Saint Maarten, Haití, Cuba y Guadalupe como observaciones extremas, con las siguientes contribuciones relativas a las primeras componentes principales:

	CTR dimensión 1	CTR dimensión 2
Saint Maarten	0.116	26.589
Haití	35.319	0.504
Guadalupe	0.233	11.313
Cuba	11.833	2.856

Saint Maarten se destaca por presentar valores en *Mortalidad Infantil* y *Mortalidad Neonatal* muy superiores a la media, seguido por Cuba y Martinica.

Conclusiones

En primer lugar, observamos que los factores que más diferencian a los países de América (que forman parte de la base de datos) son aquellos asociados a la edad de la población (edad, esperanzas de vida, nacimientos, defunciones, población menor de 15 años y población mayor de 65 años). A su vez, el otro factor relevante en el análisis fue la dimensión 2, asociada a las poblaciones de los países.

En base a esto último, dedujimos que las unidades de medida que presentan las variables en la base de datos original constituyen un aspecto importante del estudio, teniendo influencia en la interpretación de los resultados. En nuestro caso, las variables Nacimientos y Defunciones estaban representadas en cantidad y fue necesario convertirlas en unas nuevas variables ponderadas respecto a la población total de cada país.

En relación al problema de datos faltantes, se analizaron distintas estrategias para la imputación, dos de las más simples: imputación por la media e imputación por el vecino más cercano. Al comparar ambas, observamos que no se presentaban diferencias considerables en los análisis, por lo tanto, optamos por realizar una imputación por la media.

Por último, observamos que resulta sumamente enriquecedor evaluar las correlaciones dos a dos entre las variables. Esto nos permite hacer un agrupamiento entre ellas y ordenar de mejor forma a los individuos, obteniendo interpretaciones comparables entre países.

Anexo

Datos sin agrupar imputados por el vecino más cercano.

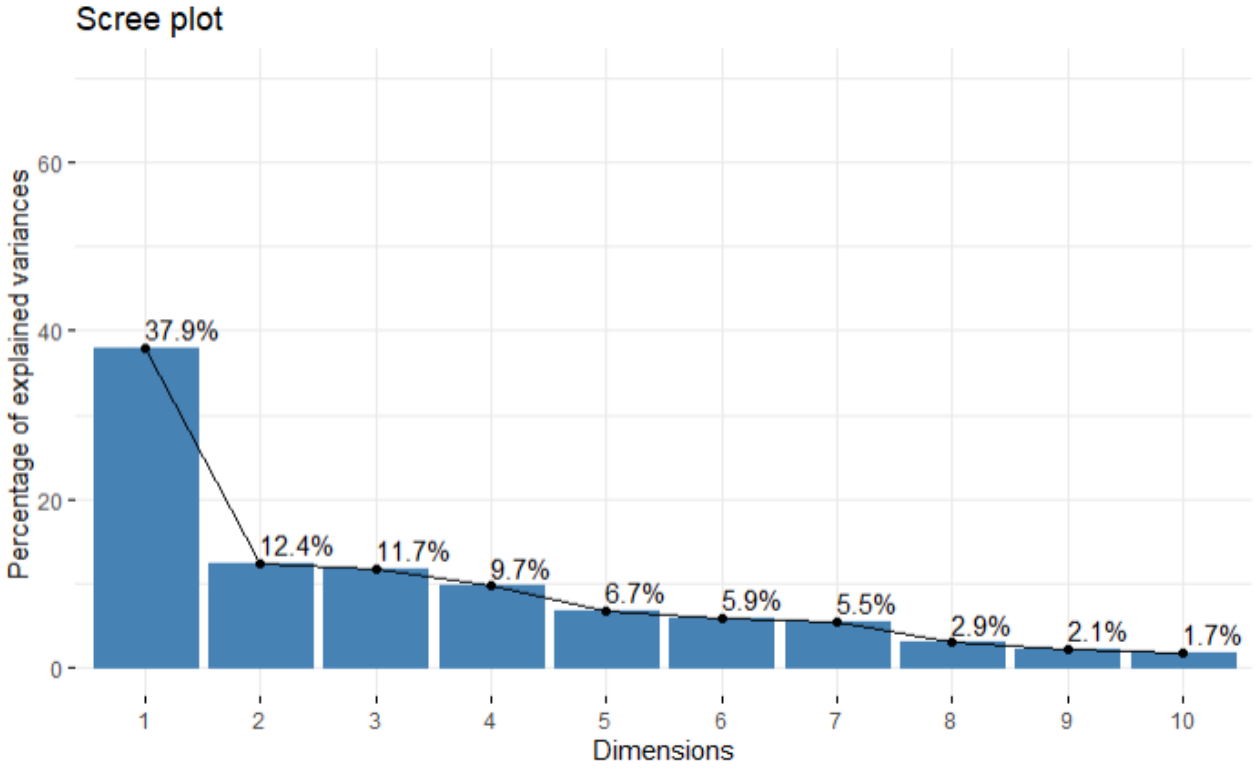
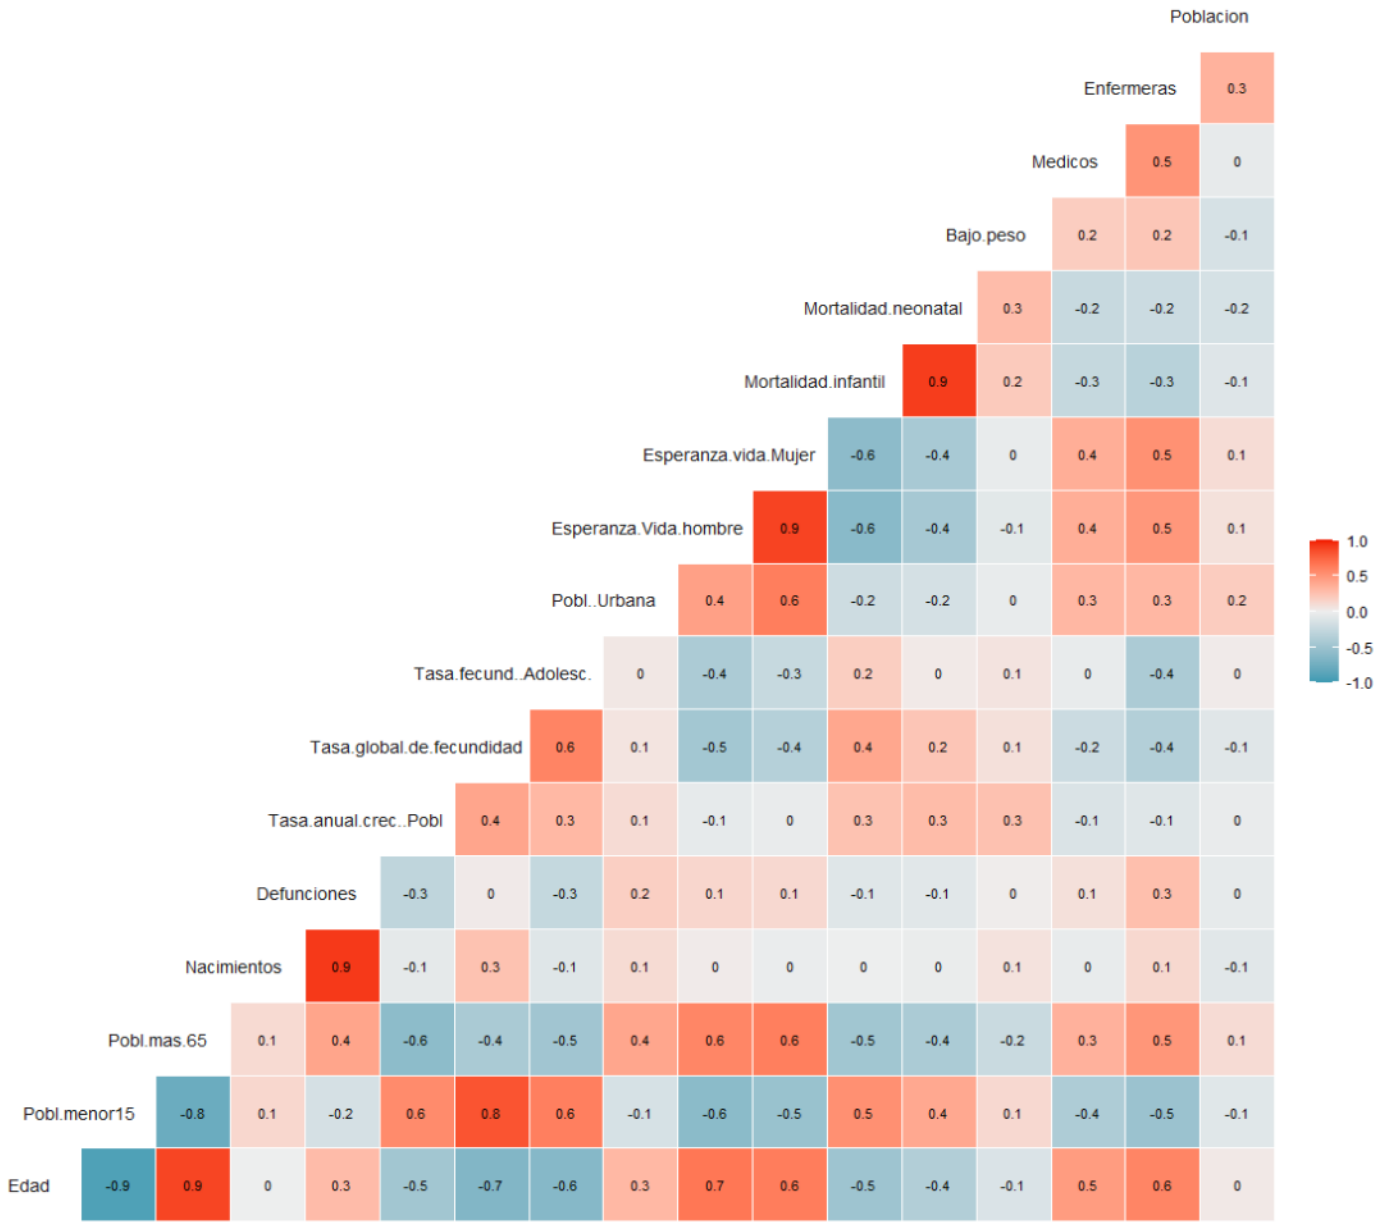


Gráfico porcentaje de varianza explicada por las primeras diez dimensiones.

Resultados del Análisis de Componentes Principales por Grupos imputando valores faltantes con el vecino más cercano.

Correlaciones entre variables dos a dos



Grupo 1

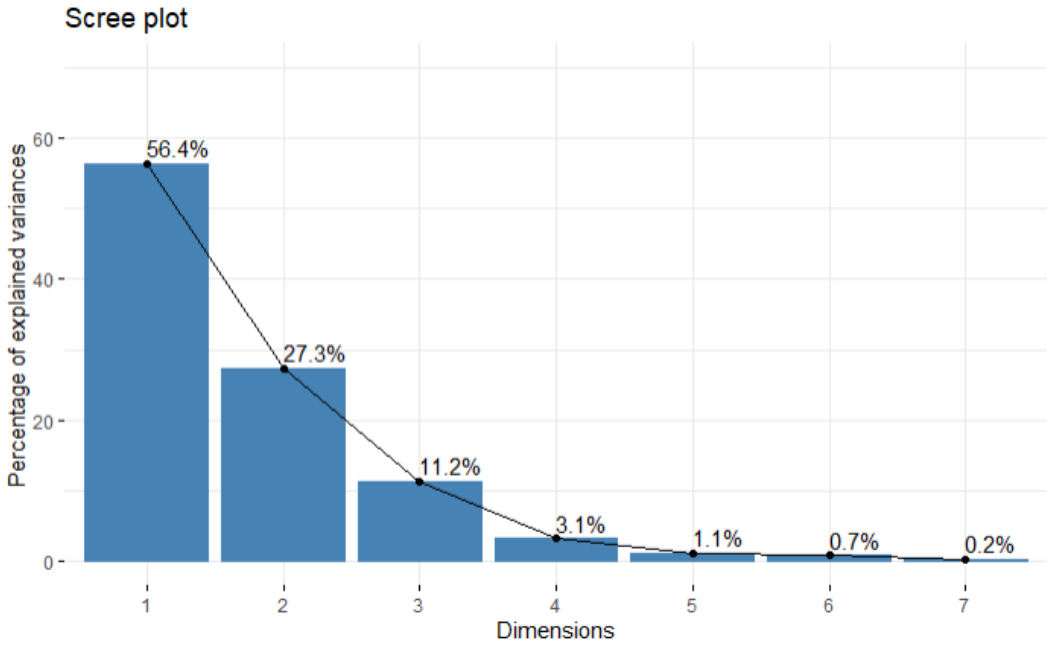


Gráfico de porcentaje de varianza explicada para las primeras siete dimensiones.

Grupo 2

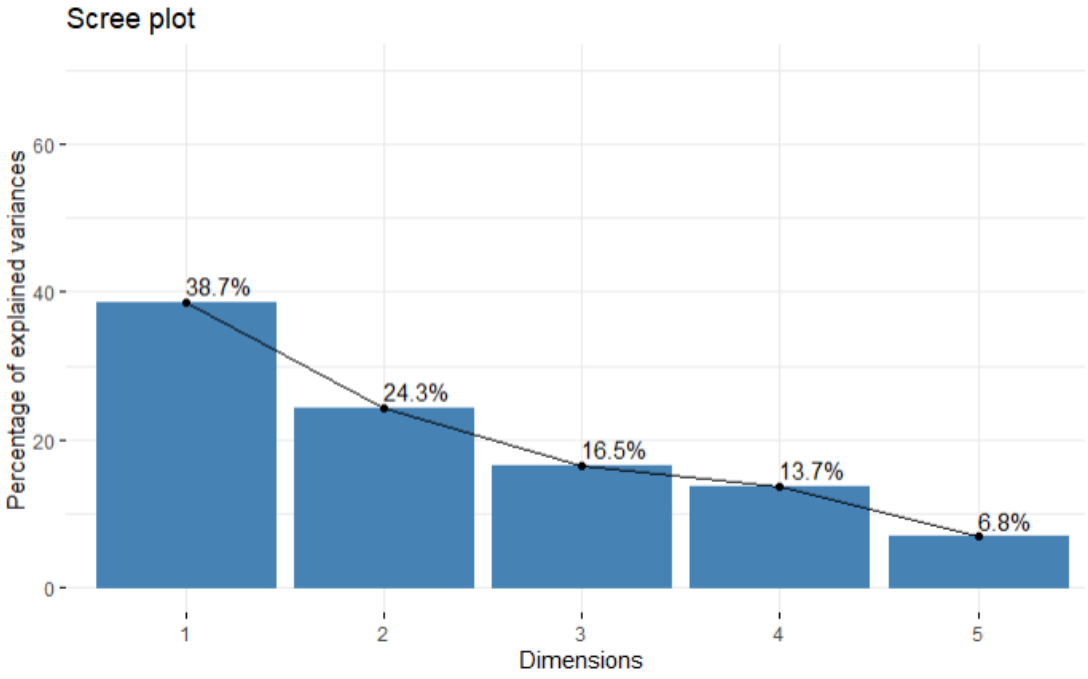


Gráfico de porcentaje de varianza explicada para las primeras cinco dimensiones.

Grupo 3

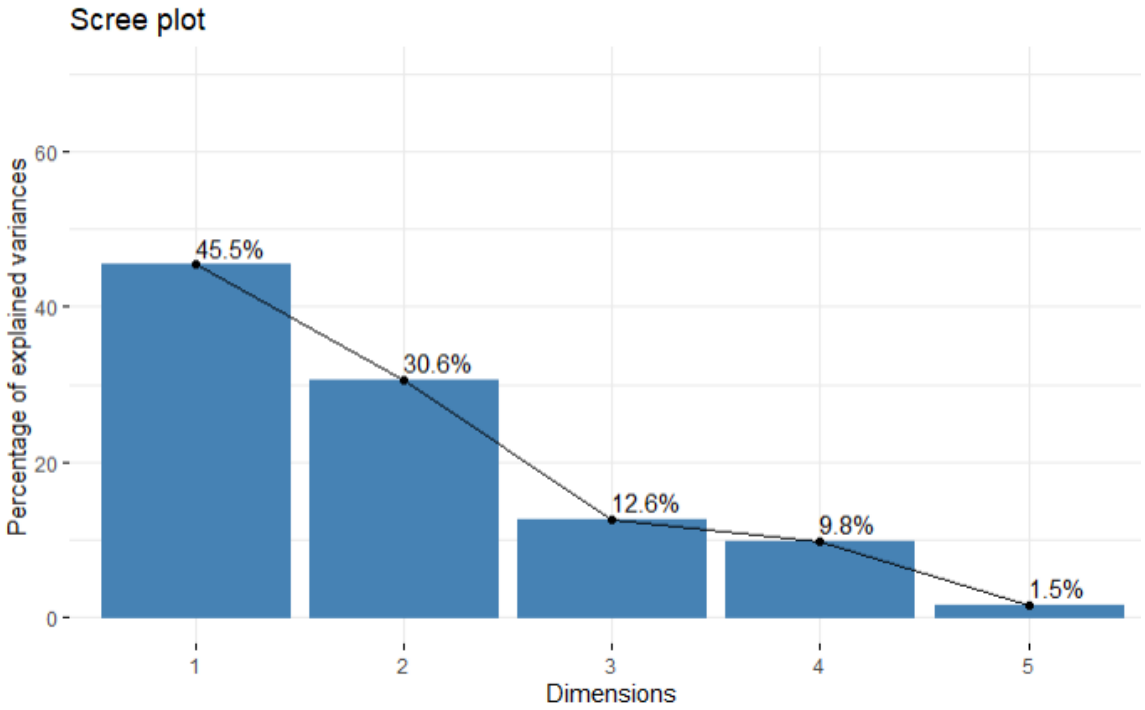


Gráfico de porcentaje de varianza explicada para las primeras cinco dimensiones.

Bibliografía

- J. Blanco. Introducción al Análisis Multivariado. Teora y Aplicaciones a la realidad latinoamericana, 2006. 1ed.
- D. Peña. Análisis Multivariado, Enero 2002.
- M. Scavino. Análisis Factorial en una nube de puntos en un espacio vectorial euclidiano. Notas del Curso Análisis Multivariado I, Instituto de Estadística (IESTA). Facultad de Ciencias Económicas y Administración (FCEA). UdelaR., 2021.
- F. Husson, S. Le, J. Pagès. Exploratory Multivariate Analysis by Example Using R. Chapman & Hall/CRC Computer Science & Data Analysis. 2017.